Costruzione di una Misura di Probabilità

Tommaso Zeri

February 2026

Contents

1 Distribuzioni di Probabilità su $\mathbb{R}^n$ **2**
1.1 Misura di Lebesgue . . . 2
1.2 Probability Density Function di una misura di probabilità . . . 2
1.3 Distributzione di una trasformazione di una VA . . . 4

2 Distribuzioni di Probabilità su $\mathbb{R}^n$ **11**
2.1 Misura di Lebesgue Multidimensionale . . . 11
2.2 Densità in $(\mathbb{R}^n, \mathcal{B}^n)$ . . . 12
2.3 Distribuzioni Continue Bivariate . . . 13
2.3.1 Normale Bivariata . . . 14
2.3.2 Lognormale Bivariata . . . 14
2.3.3 Uniforme Bivariata . . . 15
2.3.4 Esponenziale Bivariata . . . 15
2.3.5 Gamma Bivariata . . . 16
2.3.6 Weibull Bivariata . . . 17
2.3.7 Laplace Bivariata . . . 17
2.3.8 Cauchy Bivariata . . . 18
2.4 Covarianza . . . 18
2.4.1 Matrice di Covarianza . . . 18
2.5 Correlazione . . . 20
2.5.1 Matrice di Correlazione . . . 20
2.6 Distribuzione di una trasformazione di un Vettore Aleatorio . . . 21

1 Distribuzioni di Probabilità su $\mathbb{R}^n$

Abbiamo visto che una misura di probabilità $\mathbb{P}$ su $(\mathbb{R}, \mathcal{B})$ è caratterizzata dalla sua CDF $F(x) = \mathbb{P}((-\infty, x]) = \mathbb{P}(X \leq x)$.

1.1 Misura di Lebesgue

La misura di Lebesgue è una funzione $m : \mathcal{B} \to [0, \infty]$ che soddisfa:

- Additività numerabile: se $B_1, B_2, \cdots \in \mathcal{B}$ sono a due a due disgiunti, cioè $B_i \cap B_j = \emptyset$ per ogni $i \neq j$, allora:
$$m\left(\bigcup_{i=1}^{\infty} B_i\right) = \sum_{i=1}^{\infty} m(B_i)$$
- se $a, b \in \mathbb{R}$ con $a < b$, allora:
$$m((a, b]) = b - a$$

La misura di Lebesgue è la generalizzazione del concetto di lunghezza in $\mathbb{R}$, di area in $\mathbb{R}^2$ e di volume in $\mathbb{R}^3$. Essa associa ad ogni insieme boreliano della Borel σ-algebra un numero non negativo.

Unicità ed Esistenza

La Misura di Lebesgue esiste ed è unica.

Abbiamo visto che se conosciamo la CDF, allora conosciamo automaticamente tutta la misura di probabilità $\mathbb{P}$. Ora vogliamo usare questa logica su una misura che non calcola probabilità ma lunghezze. Se la CDF esiste ed è valida, allora esiste anche la misura m che essa caratterizza.

La teoria dell'integrazione vista nel capitolo 10 rimane valida se sostituiamo la misura di probabilità con quella di Lebesgue. L'unica differenza è che $m(\mathbb{R})$ non è uguale a 1 come $\mathbb{P}(\Omega)$ con $\Omega = \mathbb{R}$, ma a $+\infty$. Tutti i risultati del capitolo 10 rimangono validi ad eccezione dell'affermazione secondo cui ogni funzione di Borel limitata è integrabile:

"*Ogni VA limitata (funzione misurabile limitata) è integrabile*"

In probabilità, se abbiamo una funzione limitata come $f(x) = 5$, l'integrale su tutto lo spazio è al massimo $5 \times 1 = 5$. Con la misura di Lebesgue, l'integrale su tutto lo spazio sarebbe $5 \times \infty = \infty$.

Inoltre è falsa anche la seguente affermazione del capitolo 10:

"*Vale l'inclusione* $L^2 \subset L^1$"

L^2 è lo spazio delle funzioni quadrato-integrabili, L^1 è lo spazio delle funzioni integrabili. In probabilità ciò significa che se il momento secondo di una VA esiste finito, allora esisterà finito anche il momento primo. Con la misura di Lebesgue su $\mathbb{R}$, invece, esistono funzioni quadrato-integrabili che non sono integrabili in L^1 (e viceversa).

1.2 Probability Density Function di una misura di probabilità

La densità di una misura di probabilità $\mathbb{P}$ su $(\mathbb{R}, \mathcal{B})$ è una funzione positiva e Borel-misurabile f che, per ogni $x \in \mathbb{R}$ verifica:
$$\mathbb{P}((-\infty, x]) = \int_{-\infty}^{x} f(y)dy = \int f(y)\mathbb{1}_{(-\infty,x]}dy$$
se $\mathbb{P} = P_X$, allora f è la densità della VA X.

La PDF f è la derivata della CDF e la CDF è l'integrale della PDF, a meno di punti di non derivabilità a cui assegnamo misura nulla.

N.B.: Non tutte le distribuzioni di probabilità ammettono una funzione di densità (PDF). Ad esempio, nel caso delle variabili discrete, la densità non esiste (rispetto alla misura di Lebesgue) poiché la funzione

di ripartizione (CDF) F non è continua, ma presenta dei salti.

È fondamentale ricordare che se una variabile aleatoria ammette una densità f, allora la sua CDF F sarà sicuramente continua, ma **non è vero il contrario**. In analisi avanzata e in teoria della misura, affinché una funzione F ammetta una densità, non è sufficiente che sia semplicemente continua: deve essere **assolutamente continua**.

Un celebre caso patologico che dimostra come la sola continuità non sia sufficiente è la distribuzione di Cantor, la cui CDF è nota come "scalinata del diavolo". Questa funzione è definita sull'intervallo $[0, 1]$, cresce in modo monotono da 0 a 1 ed è *continua in ogni suo punto* (pertanto non descrive una variabile discreta, non essendoci salti).

Tuttavia, la sua peculiarità è di essere "piatta" quasi ovunque: la sua derivata è pari a zero su un insieme di misura di Lebesgue pari a 1. Poiché la derivata è nulla quasi dappertutto, il suo integrale vale 0, rendendo impossibile ricostruire la funzione F originaria integrandone la derivata.

Di conseguenza, la scalinata del diavolo è una funzione continua ma *non* assolutamente continua, e rappresenta una distribuzione di probabilità (detta *singolare continua*) che non ammette alcuna funzione di densità.

Validità di una densità

Una funzione positiva Borel-misurabile f su $\mathbb{R}$ è la densità di una misura di probabilità su $(\mathbb{R}, \mathcal{B})$ se e solo se:

$$\int f(x)dx = 1$$

In questo caso essa determina intermanete la misura di probabilità, e qualsiasi altra funzione positiva Borel-misurabile g tale che $m(f \neq g) = 0$ (cioè $f = g$ A.S.) è anch'essa una densità per la stessa misura di probabilità.
Viceversa, una misura di probabilità su $(\mathbb{R}, \mathcal{B})$ determina la sua densità (quando esiste) a meno di un insieme di misura di Lebesgue nulla (cioè se f e g sono due densità per questa misura di probabilità, allora $m(f \neq g) = 0$.

Questo teorema stabilisce due concetti fondamentali sulla relazione tra una misura di probabilità e la sua funzione di densità (PDF), basandosi sulla teoria dell'integrazione di Lebesgue:

- **Condizione di Normalizzazione:** La prima parte afferma semplicemente che affinché una funzione non negativa possa rappresentare una probabilità, l'area totale sottesa al suo grafico deve essere esattamente 1. Questa è la traduzione analitica dell'assioma fondamentale secondo cui la probabilità dell'intero spazio campionario è il 100%.
- **Unicità "Quasi Ovunque" (A.E. o A.S.):** La seconda parte è la più profonda e chiarisce il concetto di equivalenza tra densità. In teoria della misura, ciò che accade su insiemi di "lunghezza zero" (cioè di misura di Lebesgue nulla, $m = 0$) non altera in alcun modo il calcolo degli integrali.
- **Cosa significa all'atto pratico?** Significa che puoi prendere una densità valida f e modificarne il valore in un punto singolo, in cento punti, o persino in un'infinità numerabile di punti (creando una nuova funzione g). Poiché l'insieme dei punti che hai modificato ha misura di Lebesgue nulla ($m(f \neq g) = 0$), l'integrale non subirà variazioni:

$$\int_A f(x)dx = \int_A g(x)dx \quad \text{per ogni insieme misurabile } A$$

In sintesi, la densità associata a una distribuzione di probabilità esiste ed è unica, ma solo *a meno di insiemi di misura nulla*. In probabilità continua, non ha alcun senso matematico preoccuparsi del "valore esatto della densità in un singolo punto", perché alterare la funzione su singoli punti non cambia la misura di probabilità globale che essa definisce.

Una funzione f è una densità valida se:

- f deve essere sempre positiva o nulla ($f(x) \geq 0$)
- L'area totale deve essere esattamente 1 ($(x)dx = 1$)

Corollario: Expectation Rule

Sia X una VA a valori reali con densità f. Sia g una funzione Borel-misurabile. Allora g è integrabile rispetto a P_X (la distribution measure di X) se e solo se il prodotto fg è integrabile rispetto alla misura di Lebesgue. In questo caso si ha:

$$\mathbb{E}[g(X)] = \int g(X)P_X(x)dx = \int g(X)f(x)dx$$

g e una trasformazione Borel-misurabile di X. Per esempio, se $g : g(x) = x^2$, allora $\mathbb{E}[g(X)] = \mathbb{E}[X^2] = \int x^2 f(x)$.

Questo corollario è universalmente noto in letteratura come LOTUS - *Law of the Unconscious Statistician.* Stabilisce un principio di importanza pratica monumentale per il calcolo delle probabilità:

- **Il problema:** Se applichiamo una trasformazione g a una variabile aleatoria X, otteniamo una nuova variabile aleatoria $Y = g(X)$. Per calcolare il valore atteso di Y seguendo la definizione classica, dovremmo prima calcolare la nuova funzione di densità $f_Y(y)$, un processo analitico spesso lungo e complesso.
- **La soluzione (LOTUS):** Il teorema ci dice che *non è necessario conoscere la densità della nuova variabile* Y. Possiamo calcolare il valore atteso della trasformata usando semplicemente la densità $f(x)$ della variabile originale X.
- **Perché "Inconsapevole"?** Il nome deriva dal fatto che molti studenti (o statistici alle prime armi) calcolano $\mathbb{E}[g(X)]$ inserendo intuitivamente $g(x)$ dentro l'integrale di $f(x)$, convinti di applicare la definizione di valore atteso. In realtà stanno "inconsapevolmente" usando un corollario avanzato di teoria della misura che garantisce che questa scorciatoia intuitiva sia matematicamente rigorosa.

1.3 Distributzione di una trasformazione di una VA

N.B. Per padroneggiare i teoremi sulle trasformazioni di variabili aleatorie, è essenziale avere chiari i seguenti concetti sulle funzioni reali:

- **Funzione Iniettiva ("One-to-One"):** Una funzione è iniettiva se a input diversi corrispondono *sempre* output diversi. Graficamente, tracciando una qualsiasi retta orizzontale, questa intersecherà il grafico della funzione **al massimo una volta**. In formule: se $f(x_1) = f(x_2)$, allora obbligatoriamente $x_1 = x_2$.
- **Funzione Suriettiva ("Onto"):** Una funzione è suriettiva se ogni possibile valore del codominio (l'asse y di arrivo) viene "colpito" da almeno una x. In altre parole, l'immagine della funzione coincide con l'intero codominio.
- **Funzione Biiettiva (o Biunivoca):** È una funzione che è contemporaneamente sia iniettiva che suriettiva. Questa è la condizione perfetta: stabilisce una corrispondenza "uno a uno" tra le x e le y. **Solo le funzioni biiettive ammettono una funzione inversa globale** $f^{-1}(y)$.

Il rapporto cruciale con le Derivate (Monotonia)

- **Derivata mai nulla (Iniettività garantita):** Se la derivata prima $f'(x)$ non cambia mai segno (è *sempre* > 0 o *sempre* < 0), la funzione è **strettamente monotona** (sempre crescente o sempre decrescente). Una funzione strettamente monotona non "torna mai indietro", quindi è automaticamente **iniettiva** e invertibile. (Questo è il motivo per cui il Corollario 1 richiede una derivata mai nulla).
- **Derivata che si annulla e cambia segno (Perdita di iniettività):** Se $f'(x)$ passa da negativa a positiva (o viceversa), significa che la funzione ha un minimo o un massimo (come la parabola $Y = X^2$ in $x = 0$). La funzione "torna indietro", permettendo a una retta orizzontale di intersecare

il grafico due o più volte. Qui **l'iniettività crolla**, e per trovare le probabilità sarai obbligato a usare il Corollario 2, spezzando il dominio esattamente nei punti in cui $f'(x) = 0$.

Teorema del Cambio di Variabile

Sia X una VA con densità f_X e sia g una funzione Borel-misurabile. Sia $Y = g(X)$ una trasformazione della VA X. Allora:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \int_{\{u:g(u)\leq y\}} f_X(u)du$$

Dove il dominio di integrazione è costituito dai punti in cui $g(X) \leq y$.

Se F_Y è differenziabile allora possiamo usare il teorema per trovare la densità.

Questo risultato, noto formalmente come **Metodo della CDF**, è lo strumento analitico più generale e potente per ricavare la distribuzione di una variabile aleatoria trasformata $Y = g(X)$.

Ecco i punti chiave per comprenderne l'utilità e il funzionamento:

- **Validità universale:** A differenza di altre formule più rapide (come il teorema del cambio di variabile che utilizza la derivata della funzione inversa), questo integrale funziona **sempre**. In particolare, è il metodo da utilizzare obbligatoriamente quando la funzione $g(x)$ *non è iniettiva* (ad esempio le parabole $Y = X^2$ o i valori assoluti $Y = |X|$), casi in cui le formule inverse falliscono.
- **Traduzione degli eventi:** Il cuore logico del teorema è un "cambio di vocabolario". Poiché non conosciamo nulla della nuova variabile Y, traduciamo l'evento $\{Y \leq y\}$ nel suo esatto equivalente basato sulla vecchia variabile: l'evento $\{g(X) \leq y\}$.
- **Determinazione del dominio:** All'atto pratico, applicare il teorema significa risolvere la disuguaglianza $g(x) \leq y$ trattando y come un parametro fisso. Le soluzioni di questa disuguaglianza ti indicheranno esattamente quali intervalli di x devi usare come estremi per integrare la densità originale $f_X(x)$.
- **Dalla CDF alla PDF:** Il risultato di questo calcolo integrale è la funzione di ripartizione $F_Y(y)$. Se il problema richiede la funzione di densità $f_Y(y)$ della nuova variabile, il passaggio finale consiste semplicemente nel derivare il risultato ottenuto:

$$f_Y(y) = \frac{d}{dy}F_Y(y)$$

Esempio: Sia X una variabile aleatoria con distribuzione uniforme su $[0, 1]$ e sia $Y = -\frac{1}{\lambda}\log(X)$, con $\lambda > 0$.

Allora la funzione di ripartizione (CDF) di Y è:

$$\begin{aligned} F_Y(y) &= \mathbb{P}\left(-\frac{1}{\lambda}\log(X) \leq y\right) \\ &= \mathbb{P}(\log(X) \geq -\lambda y) \\ &= \mathbb{P}(X \geq e^{-\lambda y}) \\ &= \begin{cases} 1 - e^{-\lambda y} & \text{per } y \geq 0 \\ 0 & \text{altrimenti} \end{cases} \end{aligned}$$

Pertanto, derivando rispetto a y otteniamo la funzione di densità (PDF):

$$f_Y(y) = \frac{d}{dy}F_Y(y) = \begin{cases} \lambda e^{-\lambda y} & \text{se } y > 0 \\ 0 & \text{se } y \leq 0 \end{cases}$$

e vediamo chiaramente che Y segue una distribuzione esponenziale di parametro λ.

N.B.: L'esempio precedente è ingannevolmente semplice perché la funzione di trasformazione $g(x) = -\frac{1}{\lambda}\log(x)$ era iniettiva (o "uno-a-uno", cioè strettamente monotona). Il risultato generale per trasformazioni non iniettive è fornito di seguito:

Teorema del cambio di variabile (funzioni iniettive)

Sia X una VA con densità continua f_X. Sia $g : \mathbb{R} \to \mathbb{R}$ una funzione continuamente differenziabile[a] con derivata mai nulla (quindi g è monotona). sia $h(y) = g^{-1}(y)$ la funzione inversa (anch'essa continuamente differenziabile). Allora $Y = g(X)$ ha la densità:

$$f_Y(y) = f_X(h(y)) \times |h^{'}(y)|$$

[a]Una funzione si dice *continuamente differenziabile* (o di classe C^1) se ammette derivata in ogni punto del suo dominio e se tale funzione derivata è a sua volta continua, garantendo così un grafico "liscio" e privo di punti angolosi.

Questo corollario rappresenta il metodo più rapido e diretto per trovare la densità di una variabile aleatoria trasformata, poiché permette di saltare completamente il calcolo e la derivazione della Funzione di Ripartizione (CDF), fornendo la PDF in un solo passaggio.

Per comprendere intuitivamente la formula, possiamo scomporla nei suoi tre elementi fondamentali:

- **Il ritorno all'origine ($h(y)$):** Vogliamo calcolare la densità della nuova variabile Y in un punto y. Per farlo, dobbiamo scoprire da dove "proviene" questa probabilità. La funzione inversa $h(y) = g^{-1}(y)$ agisce come una macchina del tempo: prende il valore y e ci dice esattamente quale valore originario x lo ha generato.
- **La densità di partenza ($f_X(h(y))$):** Una volta scoperto il punto originario x, andiamo a leggere quanta "massa di probabilità" c'era in quel punto valutando la densità originale f_X.
- **Il fattore di distorsione ($|h'(y)|$):** Questa è la componente più brillante del teorema. Applicare una funzione $g(x)$ non significa solo "spostare" i punti sull'asse, ma spesso li *stira* o li *comprime*. Questo significa che la densità di probabilità si diluisce o si concentra. La derivata dell'inversa (che in più dimensioni prenderà il nome di *Jacobiano*) serve esattamente a misurare e compensare questa deformazione geometrica dello spazio, garantendo che l'area totale rimanga 1.

Perché il valore assoluto? La densità di probabilità, per definizione, non può mai essere un numero negativo. Se la trasformazione $g(x)$ fosse strettamente decrescente, la derivata della sua inversa sarebbe negativa. Il valore assoluto assicura che il fattore di scala rimanga positivo, preservando la correttezza della PDF geometrica.

Teorema del Cambio di Variabile (funzioni non iniettive)

Sia X una VA con densità continua f_X. Sia $g : \mathbb{R} \to \mathbb{R}$ una funzione continuamente differenziabile e monotona a tratti. Questo significa che esistono intervalli disgiunti $I_1, I_2, \ldots, I_n$ che formano una partizione di $\mathbb{R}$ tali che, su ogni intervallo I_i, la restrizione della funzione $g_i : I_i \to g(I_i)$ sia strettamente monotona (e quindi invertibile).
Sia $h_i(y) = g_i^{-1}(y)$ la funzione inversa definita sull'immagine dell'intervallo I_i. Allora la variabile trasformata $Y = g(X)$ ha densità:

$$f_Y(y) = \sum_{i=1}^{n} f_X(h_i(y)) \cdot |h_i'(y)| \cdot \mathbb{1}_{g(I_i)}(y)$$

Questo corollario generalizza il teorema precedente per gestire le **funzioni non iniettive** (come la parabola $Y = X^2$, il valore assoluto $Y = |X|$ o le funzioni trigonometriche). In questi casi, la funzione "sale e scende", il che significa che un singolo valore finale y può essere stato generato da più valori iniziali distinti di x.

Ecco la logica passo-passo che si cela dietro la formula:

- **Il "Divide et Impera" ($I_1, I_2, \ldots, I_n$):** Poiché non possiamo calcolare un'unica funzione inversa per tutta $g(x)$, spezziamo il dominio originale (l'asse x) in intervalli più piccoli all'interno dei quali

la funzione si comporta "bene" (cioè o è sempre crescente, o è sempre decrescente).

- **Applicazione del caso iniettivo:** Su ciascuno di questi singoli "pezzi", la funzione è iniettiva. Possiamo quindi calcolare l'inversa locale $h_i(y)$ e applicare l'esatta formula che abbiamo visto per il caso iniettivo (densità originale moltiplicata per il fattore di distorsione $|h_i'(y)|$).
- **La somma delle probabilità ($\sum$):** Se un valore y può provenire da tre punti diversi sull'asse x (ad esempio, uno nel primo intervallo, uno nel secondo e uno nel terzo), la densità totale nel punto y sarà semplicemente la somma delle densità "trasportate" da ciascuno di questi tre punti originari.
- **La funzione indicatrice ($\mathbb{1}_{g(I_i)}(y)$):** Questo è un "interruttore" matematico. Vale 1 se il valore y può effettivamente essere raggiunto partendo dall'intervallo i-esimo, e vale 0 altrimenti. Serve a garantire che, nella sommatoria, non aggiungiamo probabilità da intervalli che non possono fisicamente generare quel particolare valore y.

Esempio classico ($Y = X^2$): Se vogliamo calcolare la densità di $Y = X^2$, spezziamo il dominio di X in due intervalli: $I_1 = (-\infty, 0)$ dove la funzione decresce, e $I_2 = (0, \infty)$ dove cresce. Per un dato valore $y > 0$, la probabilità finale sarà la somma delle probabilità provenienti dal ramo positivo $x = +\sqrt{y}$ e dal ramo negativo $x = -\sqrt{y}$.

Il precedente teorema con i suoi corollari spiega la tecnica per trovare la PDF quando si trasforma una VA. I metodi presentati sono 3:

- **Metodo della CDF**
  1. Scrivi la definizione: $F_Y(y) = \mathbb{P}(Y \leq y)$
  2. Sostituisci Y con $g(X)$: $\mathbb{P}(g(X) \leq y)$
  3. Isola X: $\mathbb{P}(X \leq g^{-1}(X)) = \mathbb{P}(X \leq h(y))$
  4. Deriva la CDF F_Y per trovare la PDF f_Y
- **Formula del cambio di varibaile**:
  se g e strettamente monotona, non serve fare l'integrale ogni volta, ma si applica la formula:

$$f_Y(y) = f_X(h(y)) \times |h^{'}(y)|$$

- **Formula del cambio di variabile con funzioni monotone a tratti**:
  se $g(x)$ è monotona solo in alcuni tratti, non esiste una singola funzione inversa (per risolvere $x^2 = 4$ hai due inverse: $x = 2$ e $x = -2$). Quindi partizioniamo il dominio in intervalli I_i dove la funzione è monotona e per ogni I_i applichiamo la formula del cambio di variabile, poi sommiamo i singoli contributi.

Esempio: La trasformazione $Y = X^2$

Sia X una variabile aleatoria Normale Standard, ovvero $X \sim \mathcal{N}(0,1)$, la cui funzione di densità è:

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

Vogliamo trovare la densità della variabile trasformata $Y = X^2$.

Metodo 1: Tramite il Corollario (Funzione non iniettiva) La funzione $g(x) = x^2$ non è né monotona né iniettiva su tutto $\mathbb{R}$. Dividiamo quindi il dominio in due intervalli in cui la funzione è strettamente monotona: $I_1 = (0, \infty)$ in cui cresce, e $I_2 = (-\infty, 0)$ in cui decresce.

- Sul ramo positivo (I_1), la funzione inversa è $h_1(y) = \sqrt{y}$. La sua derivata è $h_1'(y) = \frac{1}{2\sqrt{y}}$.
- Sul ramo negativo (I_2), la funzione inversa è $h_2(y) = -\sqrt{y}$. La sua derivata è $h_2'(y) = -\frac{1}{2\sqrt{y}}$.

In entrambi i casi, il valore assoluto della derivata è $|h_i'(y)| = \frac{1}{2\sqrt{y}}$.

Applicando la formula per le funzioni monotone a tratti (per $y > 0$), sommiamo i due contributi:

$$\begin{aligned} f_Y(y) &= f_X(h_1(y))|h_1'(y)| + f_X(h_2(y))|h_2'(y)| \\ &= \left(\frac{1}{\sqrt{2\pi}} e^{-y/2}\right) \frac{1}{2\sqrt{y}} + \left(\frac{1}{\sqrt{2\pi}} e^{-y/2}\right) \frac{1}{2\sqrt{y}} \\ &= \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{y}} e^{-y/2} \mathbb{1}_{(0,\infty)}(y) \end{aligned}$$

La variabile aleatoria Y così ottenuta prende il nome di **variabile aleatoria Chi-Quadro con 1 grado di libertà** (denotata con χ_1^2).

Metodo 2: "A mano" (Tramite la Funzione di Ripartizione) L'esempio precedente è sufficientemente semplice da poter essere risolto anche senza usare il teorema, applicando la definizione generale:

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) \\ &= \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y}) \\ &= F_X(\sqrt{y}) - F_X(-\sqrt{y}) \end{aligned}$$

Ora deriviamo rispetto a y per trovare la densità $f_Y(y)$, applicando la regola della catena. Ricordiamo che la derivata di $F_X(x)$ è $f_X(x)$ e che la normale standard è una funzione pari, per cui $f_X(-\sqrt{y}) = f_X(\sqrt{y})$:

$$\begin{aligned} f_Y(y) &= \frac{d}{dy} \left[F_X(\sqrt{y}) - F_X(-\sqrt{y})\right] \\ &= f_X(\sqrt{y}) \cdot \frac{d}{dy}(\sqrt{y}) - f_X(-\sqrt{y}) \cdot \frac{d}{dy}(-\sqrt{y}) \\ &= f_X(\sqrt{y}) \left(\frac{1}{2\sqrt{y}}\right) - f_X(\sqrt{y}) \left(-\frac{1}{2\sqrt{y}}\right) \\ &= 2 \cdot f_X(\sqrt{y}) \left(\frac{1}{2\sqrt{y}}\right) = f_X(\sqrt{y}) \frac{1}{\sqrt{y}} \end{aligned}$$

Sostituendo la formula della normale $f_X(\sqrt{y}) = \frac{1}{\sqrt{2\pi}} e^{-y/2}$, otteniamo esattamente lo stesso risultato del Metodo 1.

Metodo Alternativo: Cambio di Variabile tramite la Derivata Originale

Esiste una formulazione equivalente, e spesso più operativa, del Teorema del Cambio di Variabile per funzioni non iniettive. Invece di ricavare analiticamente le funzioni inverse $h_i(y)$ e calcolare le loro derivate, è possibile operare direttamente sulla derivata della funzione di trasformazione originale $g(x)$.
Sia $Y = g(X)$ e fissiamo un valore y. Se indichiamo con $x_1, x_2, \ldots, x_k$ le *radici* dell'equazione $g(x) = y$ (ovvero tutti i punti di partenza nell'asse x tali per cui la funzione "colpisce" l'altezza y), la densità di Y è data dalla somma dei contributi di ciascuna radice:

$$f_Y(y) = \sum_{x_i : g(x_i) = y} \frac{f_X(x_i)}{|g'(x_i)|}$$

Dove $g'(x_i)$ è la derivata della funzione $g(x)$ valutata in corrispondenza della radice i-esima.

Perché funziona e quando conviene usarlo:

- **Il fondamento teorico (Analisi 1):** Questo metodo non è in contraddizione con la formula delle funzioni inverse, ma ne è la diretta conseguenza. Il Teorema della Derivata della Funzione Inversa stabilisce infatti che la derivata dell'inversa è l'esatto reciproco della derivata della funzione originale valutata nel punto corrispondente:

  $$|h_i'(y)| = \frac{1}{|g'(x_i)|}$$

  Sostituendo questa identità nella formula del libro, la moltiplicazione per $|h_i'(y)|$ si trasforma magicamente in una divisione per $|g'(x_i)|$.

- **Aggirare le inverse complesse:** È il metodo d'elezione quando la funzione $g(x)$ è facilissima da derivare, ma la sua inversa $h(y)$ è scomoda o propensa a generare errori di calcolo (es. funzioni trigonometriche, dove derivare un seno è più semplice che derivare un arcoseno).

- **Il trucco della sostituzione implicita:** Il vero superpotere di questa formula risiede nel fatto che *non è necessario conoscere il valore esatto delle radici* x_i. Poiché sappiamo per definizione che in quei punti vale l'equazione $g(x_i) = y$, ci basta calcolare la derivata $g'(x)$ e manipolarla (spesso tramite banali identità algebriche o trigonometriche) fino a far comparire il blocco $g(x)$, che sostituiremo con y. In questo modo, la x scompare dalla derivata prima ancora di doverla esplicitare.

Teorema della Trasformata Inversa

Sia F una funzione di ripartizione su $\mathbb{R}$. Sia U una variabile aleatoria distribuita uniformemente sull'intervallo $(0, 1)$, ovvero $U \sim \mathcal{U}(0, 1)$.
Definiamo l'inversa generalizzata (o funzione quantile) di F come:

$$F^{-1}(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\} \quad \text{per } u \in (0, 1)$$

Allora, la variabile aleatoria X definita come:

$$X = F^{-1}(U)$$

ha esattamente F come sua funzione di ripartizione, ovvero:

$$P(X \leq x) = F(x) \quad \forall x \in \mathbb{R}$$

Nota: Se la funzione F è continua e strettamente crescente, l'inversa generalizzata coincide con la funzione inversa classica, e possiamo scrivere più semplicemente che per $X = F^{-1}(U)$ vale $F_X(x) = F(x)$.

La Distribuzione Chi-Quadro (χ^2)

La distribuzione Chi-Quadro gioca un ruolo importante in Statistica. Sia p un numero intero positivo. Una variabile aleatoria X si dice avere densità Chi-Quadro con p gradi di libertà (denotata con χ^2_p) se la sua PDF per $x > 0$ è:

$$f(x) = \frac{1}{\Gamma(p/2)2^{p/2}} x^{p/2-1} e^{-x/2}$$

Proprietà fondamentali:

1. **Casi Particolari:** È un caso speciale della distribuzione Gamma: $X \sim \text{Gamma}(p/2, 1/2)$. Inoltre, se $p = 2$, la χ^2_2 è semplicemente una variabile aleatoria Esponenziale di parametro $\lambda = 1/2$.
2. **Relazione con la Normale:** Come dimostrato sopra, il quadrato di una singola normale standard è una χ^2_1. Generalizzando, se prendiamo p variabili normali standard indipendenti, la somma dei loro quadrati si distribuisce come una χ^2_p. Questa distribuzione emerge in modo naturale nella statistica inferenziale quando si cerca di stimare la varianza di una popolazione normale.

2 Distribuzioni di Probabilità su $\mathbb{R}^n$

Nel capitolo precedente abbiamo considerato il caso semplice delle distribuzioni su $(\mathbb{R}^1, \mathcal{B})$. Ora analizziamo il caso delle distribuzioni su $(\mathbb{R}^n, \mathcal{B}^n)$, dove $\mathcal{B}^n$ denota i Borel-sets di $\mathbb{R}^n$ ed è generata dai "quadranti" della forma:

$$\prod_{i=1}^{n}(-\infty, a_i] \quad a_i \in \mathbb{Q}$$

Si noti che $\mathcal{B}^n = \mathcal{B} \otimes \mathcal{B} \otimes ... \otimes \mathcal{B}$, ovvero $\mathcal{B}^n = \sigma(\mathcal{B} \times \mathcal{B} \times ... \times \mathcal{B})$ è la più piccola σ-algebra generata dal prodotto cartesiano n-esimo di $\mathcal{B}$.

La CDF multidimensionale di una misura di probabilità su $(\mathbb{R}^n, \mathcal{B}^n)$ è:

$$F(x_1, ..., x_n) = \mathbb{P}\left(\prod_{i=1}^{n}(-\infty, x_i]\right)$$

Cercare di caratterizzare la probabilità $\mathbb{P}$ utilizzando F per $n \geq 2$ è più delicato rispetto al caso $n = 1$. Di conseguenza, le CDF sono usate raramente su più dimensioni. Infatti, per calcolare la probabilità di un semplice rettangolo $\mathcal{R}$ in 2D, come $\mathbb{P}(a < X \leq b, c < Y \leq d)$, la formula diventa macchinosa per il principio di inclusione-esclusione:

$$\mathbb{P}(\mathcal{R}) = F(b, d) - F(a, d) - F(b, c) + F(a, c)$$

man mano che n cresce, questa somma a segni alternati diventa intrattabile. In alte dimensioni si preferisce lavorare con la PDF.

2.1 Misura di Lebesgue Multidimensionale

La misura di Lebesgue multidimensionale m_n su $(\mathbb{R}^n, \mathcal{B}^n)$ è definita per gli insiemi che sono prodotti cartesiani $A_1 \times A_2 \times ... \times A_n$.

$$m_n\left(\prod_{i=1}^{n} A_i\right) = \prod_{i=1}^{n} m_1(A_i) \qquad \forall A_i \in \mathcal{B}$$

Come visto nel capitolo precedente, si può estendere la misura di Lebesgue per i prodotti cartesiani (definiti come $A \times B = \{(a, b) : a \in A, b \in B\}$, ovvero l'insieme di tutte le coppie ordinate (a, b)) in modo unico, a una misura m_n su $(\mathbb{R}^n, \mathcal{B}^n)$, e m_n manterrà le proprietà di additività numerabile. Tale misura m_n è una misura di Lebesgue, ed è caratterizzata anche dalla seguente condizione (più debole rispetto alla prima):

$$m_n\left(\prod_{i=1}^{n}(a_i, bi]\right) = \prod_{i=1}^{n}(b_i - a_i) \qquad \forall -\infty < a_i < b_i < \infty$$

Se $A \in \mathcal{B}^n$, si può considerare $m_n(A)$ come il volume dell'insieme A:

$$\int f(x)d\mathbf{x} = \int f(x_1, ..., x_n)dx_1...dx_n$$

dove $dx_1...dx_n = m_n$. E scriviamo anche:

$$\int_A f(x)d\mathbf{x} = \int f(x)\mathbb{1}_A d\mathbf{x}$$

per indicare l'integrale sull'insieme di interesse $A \in \mathcal{B}^n$.

N.B.: in 1D ($\mathbb{R}$), la misura di Lebesgue m è semplicemente la lunghezza di un intervallo $(a, b]$ ottenuta come $m(a, b] = b - a$. (aperto a sx e chiuso a dx per garantire che si incastrino alla perfezione rimanendo disgiunti). Se hai un rettangolo ($\mathbb{R}^2$) di base A_1 e altezza A_2, la sua area m_2 si calcola come $m_2(A_1 \times A_2) = m_1(A_1) \times m_1(A_2)$. E cosi via per $\mathbb{R}^{n \geq 2}$.
Calcolare il volume di una forma nota è semplice, ma come calcoliamo il volume di un insieme frastagliato in $\mathcal{B}^n$? Il teorema di estensione ci garantisce che se sappiamo come misurare il volume di una forma semplice (come un rettangolo), esiste un modo logico di risalire al calcolo del volume della forma difficile attraverso i volumi delle forme semplici.

2.2 Densità in $(\mathbb{R}^n, \mathcal{B}^n)$

Una misura di probabilità $\mathbb{P}$ su $(\mathbb{R}^n, \mathcal{B}^n)$ ha una densità f se f è una funzione non-negativa, Borel-misurabile su $\mathbb{R}^n$ che verifica, $\forall A \in \mathcal{B}^n$:

$$\mathbb{P}(A) = \int f(x)\mathbb{1}_A d\mathbf{x} = \int_A f(x)d\mathbf{x} = \int f(x_1, ...x_n)\mathbb{1}_A(x_1, ...x_n)dx_1, ...dx_n$$

N.B.: non tutte le probabilità su $(\mathbb{R}^n, \mathcal{B}^n)$ ammettono una densità.

Condizione per essere una densità

Una funzione positiva e Borel-misurabile f su $\mathbb{R}^n$ è la densità di una misura di probabilità su $(\mathbb{R}^n, \mathcal{B}^n)$ se e solo se soddisfa:

$$\int f(x)d\mathbf{x} = 1$$

In questo caso essa determina interamente la misura di probabilità, e qualsiasi altra funzione Borel-misurabile g tale che $m_n(f = g) = 0$ (quindi $f = g$ quasi ovunque, tranne che su insiemi di misura di Lebesgue nulla) è anch'essa una densità per la stessa misura di probabilità.
Viceversa, una misura di probabilità su $(\mathbb{R}^n, \mathcal{B}^n)$ determina la sua densità (quando esiste) a meno di un insieme di misura di Lebesgue nulla (cioè se f e g sono due densità per questa probabilità, allora $m_n(f \neq g) = 0$ che si scrive $f = g$ $m_n - a.e.$ almost everywhere.

Ora per comodità, lavoriamo in $\mathbb{R}^2$. Sia $\mathbf{X}$ un vettore aleatorio con componenti Y, Z, ovvero $\mathbf{X} = [Y, Z]$.

Densità Multivariata

Supponiamo che $\mathbf{X} = [Y, Z]$ abbia una densità f su $\mathbb{R}^2$. Allora:

- Sia Y sia Z hanno densità su $(\mathbb{R}, \mathcal{B})$ date da:

  $$f_Y(y) = \int_{\mathbb{R}} f(y, z)\, dz \qquad \text{e} \qquad f_Z(z) = \int_{\mathbb{R}} f(y, z)\, dy$$

  Queste sono le densità marginali.
- Le componenti Y e Z sono indipendenti se e solo se:

  $$f(y, z) = f_Y(y)f_Z(z) \quad dm_2\text{-a.e.}$$

  Cioè se e solo se la densità congiunta di $\mathbf{X}$ può essere fattorizzata come il prodotto delle densità marginali delle componenti Y e Z.
- La formula sottostante definisce un'altra densità su $\mathbb{R}$ in ogni punto $y \in \mathbb{R}$ tale che $f_Y(y) \neq 0$:

  $$f_{Y=y}(z) = \frac{f(y, z)}{f_Y(y)}$$

  Questa è la densità condizionale di Z dato $Y = y$ (dove y non è un singolo punto, poichè altrimenti la probabilità sarebbe 0, bensì un intervallo infinitesimale)

Questi punti descrivono il comportamento di un **vettore aleatorio continuo** $\mathbf{X} = [Y, Z]$, dove stiamo analizzando contemporaneamente due variabili casuali per capire come interagiscono tra loro nello spazio bidimensionale $\mathbb{R}^2$.

1. La Densità Congiunta

Partiamo dal presupposto che $\mathbf{X} = [Y, Z]$ abbia una densità di probabilità congiunta $f(y, z)$. In termini intuitivi, puoi immaginare $f(y, z)$ come una "montagna" tridimensionale (una superficie) che sovrasta il piano $\mathbb{R}^2$. L'altezza della montagna nel punto (y, z) indica quanto è "probabile" che il vettore $\mathbf{X}$ assuma valori nell'intorno infinitesimale di quel punto.

2. Le Densità Marginali

Le formule fornite per le **densità marginali** sono:

$$f_Y(y) = \int_{\mathbb{R}} f(y,z)\,dz$$

$$f_Z(z) = \int_{\mathbb{R}} f(y,z)\,dy$$

Spiegazione: Per trovare la densità della sola variabile Y nel punto y, dobbiamo prendere la densità congiunta $f(y,z)$ e "sommarla" (tramite l'integrale) lungo tutti i possibili valori che Z può assumere (da $-\infty$ a $+\infty$). Visivamente, equivale a "schiacciare" o proiettare la montagna 3D contro la parete dell'asse Y. Il risultato, $f_Y(y)$, descrive il comportamento di Y come se Z non esistesse.

3. Indipendenza tra Variabili

Il secondo punto definisce il concetto fondamentale di **indipendenza statistica** per variabili continue:

$$f(y,z) = f_Y(y)f_Z(z) \quad dm_2\text{-q.o.}$$

Spiegazione: Due variabili sono indipendenti se la loro densità congiunta si può "spezzare" (fattorizzare) nel prodotto delle loro densità marginali. Intuitivamente significa che il comportamento di Y non influenza in alcun modo il comportamento di Z, e viceversa. L'aggiunta di "quasi ovunque" (dm_2-q.o.) significa che l'uguaglianza può fallire su un insieme di punti di area nulla rispetto alla misura di Lebesgue, senza invalidare l'indipendenza complessiva.

4. La Densità Condizionale

L'ultimo punto introduce la **probabilità condizionata** per variabili continue. La formula classica è definita come:

$$f_{Z|Y}(z|y) = \frac{f(y,z)}{f_Y(y)} \quad \text{per } f_Y(y) > 0$$

Spiegazione: Questa formula risponde alla domanda: *"Se so di per certo che Y ha assunto il valore y, qual è ora la distribuzione di probabilità di Z?"*

Come sottolinea la nota, non stiamo condizionando a un singolo punto esatto, ma a un intervallo infinitesimale. Questo perché la probabilità puntuale per variabili continue è sempre zero.

Geometricamente, ecco cosa fa quella formula:

1. **Taglia la montagna:** Prende la funzione congiunta $f(y,z)$ e la "affetta" esattamente in corrispondenza di $Y = y$.
2. **Normalizza la fetta:** Affinché questa fetta diventi una vera funzione di densità di probabilità (che deve integrare a 1), dobbiamo dividere ogni suo punto per l'area totale della fetta, ovvero per $f_Y(y)$.

2.3 Distribuzioni Continue Bivariate

Per ciascuna delle distribuzioni continue presentate nella sezione precedente viene illustrata l'estensione bivariata della densità congiunta $f(x_1, x_2)$. Ogni figura è organizzata in due blocchi affiancati: il blocco sinistro mostra la densità come mappa cromatica nel piano (x_1, x_2) con le rispettive marginali $f(x_1)$ (in alto, blu) e $f(x_2)$ (a destra, rosso); il blocco destro riporta la stessa densità come superficie tridimensionale, accompagnata dalle medesime marginali per facilitare il confronto geometrico tra la struttura congiunta e le distribuzioni unidimensionali. Nei casi in cui le due componenti sono indipendenti la densità congiunta si fattorizza come $f(x_1, x_2) = f_1(x_1)\, f_2(x_2)$; nelle distribuzioni Normale e Lognormale viene invece introdotta una struttura di correlazione tra le due variabili tramite una matrice di covarianza non diagonale.

2.3.1 Normale Bivariata

La distribuzione Normale bivariata è la generalizzazione vettoriale della distribuzione Gaussiana. Il vettore aleatorio $\mathbf{x} = (x_1, x_2)^\top$ ha densità:

$$f(x_1, x_2) = \frac{1}{2\pi\,\sigma_1\sigma_2\sqrt{1-\rho^2}}\;\exp\!\left\{-\frac{1}{2(1-\rho^2)}\right.$$
$$\left.\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\},$$

dove $\mu_i \in \mathbb{R}$ sono le medie, $\sigma_i > 0$ le deviazioni standard e $\rho \in (-1, 1)$ il coefficiente di correlazione lineare. Le distribuzioni marginali sono Normali univariate: $x_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$. Il parametro ρ controlla la forma degli insiemi di livello della densità: per $\rho = 0$ gli ellissi hanno assi paralleli ai due assi coordinati; per $|\rho| \to 1$ la distribuzione si concentra intorno a una retta. Nella figura seguente si utilizza $\mu_1 = \mu_2 = 0$, $\sigma_1 = \sigma_2 = 1$ e $\rho = 0.6$.

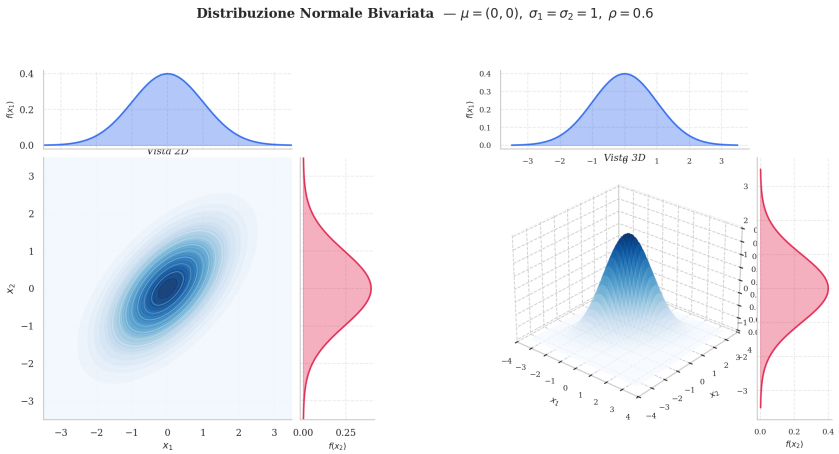


Figure 1: Normale Bivariata: $\boldsymbol{\mu} = (0, 0)$, $\sigma_1 = \sigma_2 = 1$, $\rho = 0.6$. *Sin.*: mappa cromatica con curve di livello e marginali. *Des.*: superficie tridimensionale; la campana ellittica inclinata riflette la correlazione positiva.

2.3.2 Lognormale Bivariata

Se il vettore dei logaritmi $(\log x_1, \log x_2)^\top$ segue una Normale bivariata con parametri $(\boldsymbol{\mu}_{\log}, \boldsymbol{\Sigma}_{\log})$, allora (x_1, x_2) ha distribuzione Lognormale bivariata con densità:

$$f(x_1, x_2) = \frac{1}{2\pi\,\sigma_1\sigma_2\sqrt{1-\rho^2}\,x_1 x_2}\;\exp\!\left\{-\frac{1}{2(1-\rho^2)}\right.$$
$$\left.\left[\frac{(\log x_1-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(\log x_1-\mu_1)(\log x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(\log x_2-\mu_2)^2}{\sigma_2^2}\right]\right\},$$

per $x_1, x_2 > 0$. Le marginali sono Lognormali univariate. La densità congiunta è asimmetrica a destra in entrambe le componenti e presenta un picco molto acuto vicino all'origine, con code che si estendono verso valori elevati. Nella figura si utilizza $\mu_1 = \mu_2 = 0$, $\sigma_1 = \sigma_2 = 1$ e $\rho_{\log} = 0.6$.

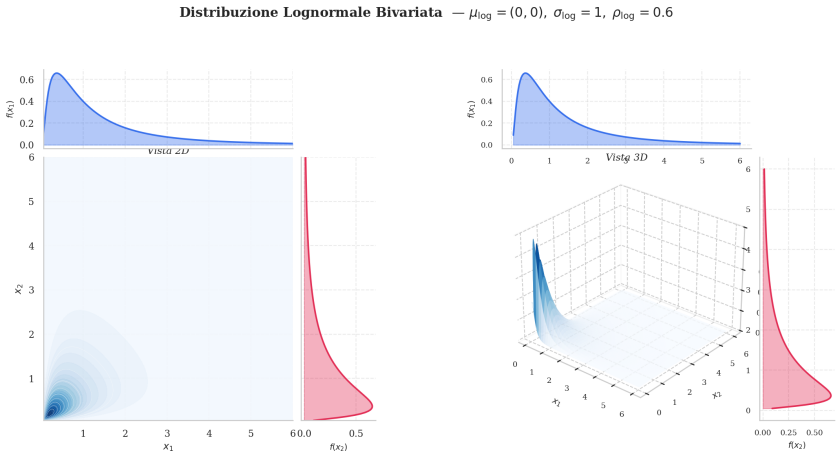


Figure 2: Lognormale Bivariata: $\mu_{\log} = 0$, $\sigma_{\log} = 1$, $\rho_{\log} = 0.6$. *Sin.*: densità concentrata vicino all'origine con coda asimmetrica verso destra. *Des.*: picco stretto e asimmetria caratteristica della distribuzione.

2.3.3 Uniforme Bivariata

Il vettore (x_1, x_2) ha distribuzione Uniforme bivariata sul rettangolo $[a, b] \times [c, d]$ se la sua densità congiunta è:

$$f(x_1, x_2) = \frac{1}{(b-a)(d-c)}, \qquad (x_1, x_2) \in [a, b] \times [c, d],$$

e zero altrove. Poiché la densità si fattorizza come il prodotto di due densità Uniformi univariate, x_1 e x_2 sono per costruzione indipendenti. Le marginali sono $x_1 \sim U(a, b)$ e $x_2 \sim U(c, d)$. Nella figura si utilizza $a = 0$, $b = 3$, $c = 0$, $d = 2$.

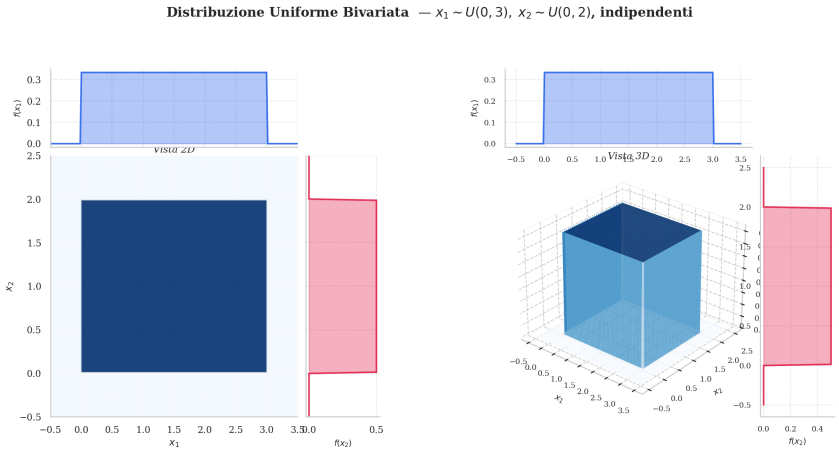


Figure 3: Uniforme Bivariata: $x_1 \sim U(0, 3)$, $x_2 \sim U(0, 2)$, componenti indipendenti. *Sin.*: densità costante sul rettangolo di supporto. *Des.*: plateau perfettamente piatto.

2.3.4 Esponenziale Bivariata

Nel caso di componenti indipendenti, il vettore (x_1, x_2) ha densità congiunta:

$$f(x_1, x_2) = \beta_1 e^{-\beta_1 x_1} \cdot \beta_2 e^{-\beta_2 x_2}, \qquad x_1, x_2 \geq 0,$$

con $\beta_1, \beta_2 > 0$. La densità congiunta raggiunge il suo massimo nell'origine $(0, 0)$ e decresce monotonicamente in entrambe le direzioni. Le marginali sono $x_1 \sim \text{Exp}(\beta_1)$ e $x_2 \sim \text{Exp}(\beta_2)$. Nella figura si utilizza $\beta_1 = 1$ e $\beta_2 = 1.5$.

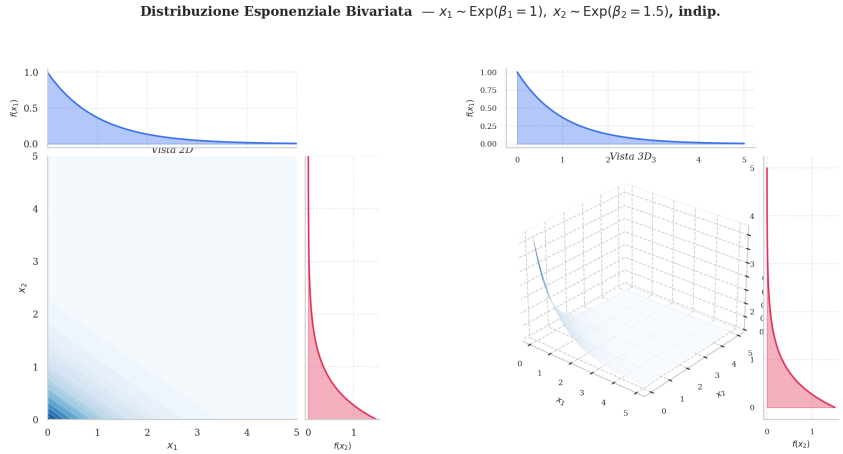


Figure 4: Esponenziale Bivariata: $\beta_1 = 1$, $\beta_2 = 1.5$, componenti indipendenti. *Sin.*: massimo nell'origine, decadimento esponenziale in entrambe le direzioni. *Des.*: picco acuto con decadimento asintotico.

2.3.5 Gamma Bivariata

Con componenti indipendenti la densità congiunta è:

$$f(x_1, x_2) = \frac{\beta_1^{\alpha_1}}{\Gamma(\alpha_1)} x_1^{\alpha_1 - 1} e^{-\beta_1 x_1} \cdot \frac{\beta_2^{\alpha_2}}{\Gamma(\alpha_2)} x_2^{\alpha_2 - 1} e^{-\beta_2 x_2}, \qquad x_1, x_2 \geq 0.$$

Per $\alpha_i > 1$ ciascuna marginale ha un massimo interno (la moda si trova in $(\alpha_i - 1)/\beta_i$), per cui la densità congiunta presenta un picco spostato dall'origine. Le marginali sono $x_1 \sim \Gamma(\alpha_1, \beta_1)$ e $x_2 \sim \Gamma(\alpha_2, \beta_2)$. Nella figura si utilizza $\alpha_1 = 2$, $\beta_1 = 1$ e $\alpha_2 = 3$, $\beta_2 = 1$.

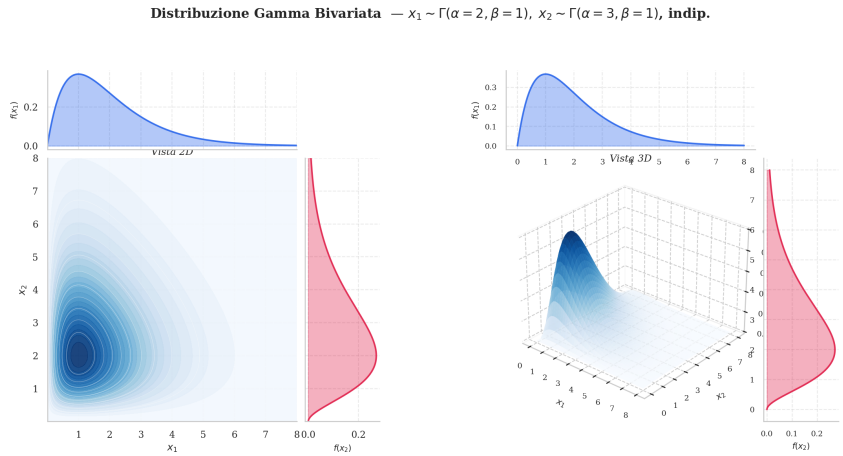


Figure 5: Gamma Bivariata: $\Gamma(\alpha_1{=}2, \beta_1{=}1)$, $\Gamma(\alpha_2{=}3, \beta_2{=}1)$, componenti indipendenti. *Sin.*: picco spostato dall'origine; mode in $x_1 = 1$ e $x_2 = 2$. *Des.*: gobba caratteristica della distribuzione Gamma.

2.3.6 Weibull Bivariata

Con componenti indipendenti la densità congiunta è:

$$f(x_1, x_2) = \alpha_1 \beta_1^{\alpha_1} x_1^{\alpha_1 - 1} e^{-(\beta_1 x_1)^{\alpha_1}} \cdot \alpha_2 \beta_2^{\alpha_2} x_2^{\alpha_2 - 1} e^{-(\beta_2 x_2)^{\alpha_2}}, \qquad x_1, x_2 \geq 0.$$

Il parametro di forma α_i determina il comportamento del tasso di guasto: per $\alpha_i > 1$ il tasso cresce nel tempo (usura), per $\alpha_i = 1$ torna alla distribuzione Esponenziale. Le marginali sono $x_1 \sim W(\alpha_1, \beta_1)$ e $x_2 \sim W(\alpha_2, \beta_2)$. Nella figura si utilizza $\alpha_1 = 2$, $\beta_1 = 1$ e $\alpha_2 = 3$, $\beta_2 = 1$.

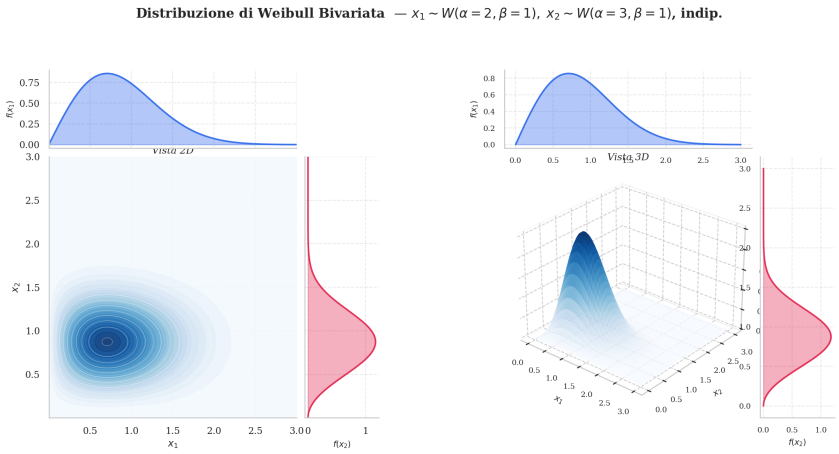


Figure 6: Weibull Bivariata: $W(\alpha_1{=}2, \beta_1{=}1)$, $W(\alpha_2{=}3, \beta_2{=}1)$, componenti indipendenti. *Sin.*: marginali con moda interna per $\alpha_i > 1$. *Des.*: gobba asimmetrica con decadimento rapido.

2.3.7 Laplace Bivariata

Con componenti indipendenti la densità congiunta è:

$$f(x_1, x_2) = \frac{\beta_1}{2} e^{-\beta_1 |x_1 - \alpha_1|} \cdot \frac{\beta_2}{2} e^{-\beta_2 |x_2 - \alpha_2|}, \qquad x_1, x_2 \in \mathbb{R}.$$

Il prodotto di due densità di Laplace produce una densità congiunta con un picco a spigolo vivo nel punto (α_1, α_2) e code esponenziali in tutte le direzioni. Le marginali sono $x_1 \sim L(\alpha_1, \beta_1)$ e $x_2 \sim L(\alpha_2, \beta_2)$. Nella figura si utilizza $\alpha_1 = \alpha_2 = 0$, $\beta_1 = 1$ e $\beta_2 = 0.7$.

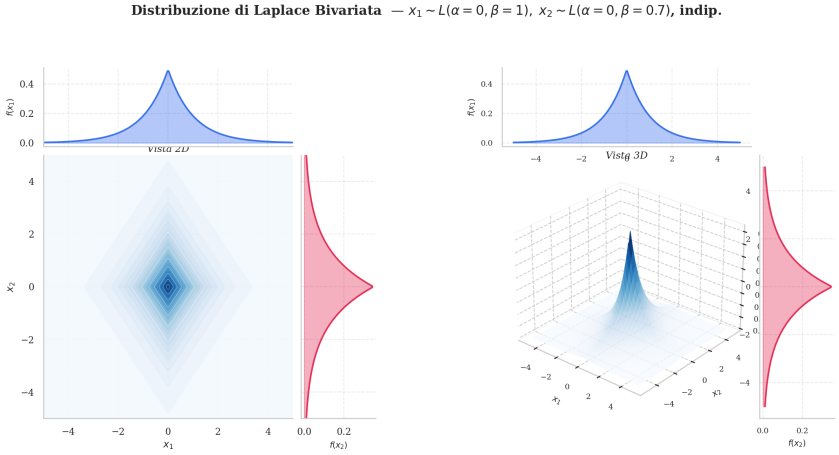


Figure 7: Laplace Bivariata: $L(\alpha_1{=}0, \beta_1{=}1)$, $L(\alpha_2{=}0, \beta_2{=}0.7)$, componenti indipendenti. *Sin.*: picco centrale con code simmetriche. *Des.*: cresta a spigolo vivo caratteristica della distribuzione di Laplace.

2.3.8 Cauchy Bivariata

Con componenti indipendenti la densità congiunta è:

$$f(x_1, x_2) = \frac{1}{\pi\beta_1\left[1+\left(\frac{x_1-\alpha_1}{\beta_1}\right)^2\right]} \cdot \frac{1}{\pi\beta_2\left[1+\left(\frac{x_2-\alpha_2}{\beta_2}\right)^2\right]}, \qquad x_1, x_2 \in \mathbb{R}.$$

La distribuzione di Cauchy ha code polinomiali (di ordine -2) molto più pesanti di quelle esponenziali della Laplace o della Normale. Di conseguenza la densità congiunta ha un picco acuto nel punto (α_1, α_2) ma la massa probabilistica nelle code è non trascurabile anche per valori molto lontani dal centro. Media e varianza non esistono per nessuna delle due marginali. Nella figura si utilizza $\alpha_1 = \alpha_2 = 0$ e $\beta_1 = \beta_2 = 1$.

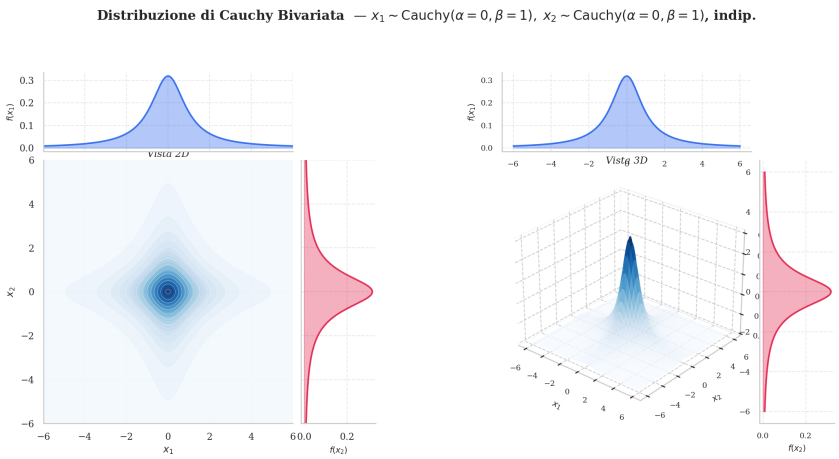


Figure 8: Cauchy Bivariata: Cauchy(α_1=0, β_1=1), Cauchy(α_2=0, β_2=1), componenti indipendenti. *Sin.*: picco stretto con code polinomiali pesanti su tutto $\mathbb{R}^2$. *Des.*: picco strettissimo; le code rendono difficile la rappresentazione simultanea del centro e della periferia.

2.4 Covarianza

Siano X e Y due VA reali, ciascuna con varianza finita. La covarianza tra X e Y è data da:

$$cov(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Si noti che $\mathbb{E}[XY]$ esiste perchè X e Y hanno varianza finita (sono entrambe in L^2) e quindi $XY \in L^1$. Vale inoltre:

$$cov(X, X) = \mathbb{V}[X]$$

Indipendenza e Covarianza

Se X e Y sono indipendenti, allora:

$$cov(X, Y) = 0$$

poichè $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$

N.B.: se $cov(X, Y) = 0$ non è detto che X e Y siano indipendenti.

2.4.1 Matrice di Covarianza

Sia $\mathbf{X} = [X_1, ..., X_n]$ un vettore aleatorio in $\mathbb{R}^n$. La matrice di covarianza di $\mathbf{X}$ è la matrice $n \times n$ il cui termine generale è $c_{i,j} = cov(X_i, X_j)$:

$$C = \begin{bmatrix} c_{1,1} & c_{1,2} & \dots & c_{1,n} \\ c_{2,1} & c_{2,2} & \dots & c_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n,1} & c_{n,2} & \dots & c_{n,n} \end{bmatrix} = \begin{bmatrix} Var(X_1) & cov(X_1, X_2) & \dots & cov(X_1, X_n) \\ cov(X_2, X_1) & Var(X_2) & \dots & cov(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ cov(X_n, X_1) & cov(X_n, X_2) & \dots & Var(X_n) \end{bmatrix}$$

Proprietà della matrice di covarianza

- Una matrice di covarianza C è semidefinita positiva[a], ovvero è simmetrica ($c_{ij} = c_{ji}$ e inoltre $\Sigma_{i,j} a_i a_j c_{ij} \geq 0 \; \forall [a_1, ..., a_n] \in \mathbb{R}^n$

- Sia $\mathbf{X}$ un vettore aleatorio a valori in $\mathbb{R}^n$, con matrice di covarianza C. Sia A una matrice $m \times n$ e poniamo $\mathbf{Y} = A\mathbf{X}$. Allora $\mathbf{Y}$ è un vettore aleatorio a valori in $\mathbb{R}^m$ e la sua matrice di covarianza è:

$$G = ACA^T$$

[a] In algebra lineare, una matrice quadrata C è semidefinita positiva se, preso un qualsiasi vettore di numeri reali $\mathbf{a} = [a_1, ..., a_n] \in \mathbb{R}^n$, la sua forma quadratica da sempre un risultato ≥ 0:

$$\mathbf{a}^T C \mathbf{a} \geq 0$$

Le proprietà elencate nel riquadro descrivono il comportamento fondamentale della matrice di covarianza C (spesso indicata anche con Σ) di un vettore aleatorio. Analizziamo i due punti nel dettaglio.

1. Simmetria e Semidefinitezza Positiva

Simmetria ($c_{ij} = c_{ji}$):
La matrice è simmetrica rispetto alla diagonale principale. Questo è un fatto banale che deriva dalla definizione stessa di covarianza: la covarianza tra la variabile X_i e la variabile X_j è identica alla covarianza tra X_j e X_i. Ovvero, $Cov(X_i, X_j) = Cov(X_j, X_i)$.

Semidefinitezza Positiva ($\mathbf{a}^T C \mathbf{a} \geq 0$):
Dal punto di vista dell'algebra lineare, hai giustamente ricordato che una matrice è semidefinita positiva se la sua forma quadratica associata non è mai negativa. Ma *perché* la matrice di covarianza deve avere per forza questa proprietà?

Il motivo è squisitamente statistico. Prendiamo il nostro vettore di numeri reali $\mathbf{a} = [a_1, \ldots, a_n]^T$ e usiamolo per creare una nuova singola variabile aleatoria Z, definita come combinazione lineare delle componenti di $\mathbf{X}$:

$$Z = a_1 X_1 + a_2 X_2 + \cdots + a_n X_n = \mathbf{a}^T \mathbf{X}$$

Per le leggi della probabilità, la **varianza** di qualsiasi variabile aleatoria (inclusa Z) non può mai essere negativa:

$$Var(Z) \geq 0$$

Se andiamo a calcolare esplicitamente la varianza di questa combinazione lineare utilizzando le proprietà della varianza e della covarianza, scopriamo che:

$$Var(Z) = Var(\mathbf{a}^T \mathbf{X}) = \sum_{i=1}^{n} \sum_{j=1}^{n} a_i a_j c_{ij} = \mathbf{a}^T C \mathbf{a}$$

Poiché la varianza deve essere ≥ 0, ne consegue necessariamente che $\mathbf{a}^T C \mathbf{a} \geq 0$. Quindi, dire che la matrice di covarianza è semidefinita positiva equivale semplicemente a dire che **"non esistono combinazioni lineari di variabili aleatorie che abbiano varianza negativa"**.

2. Trasformazione Lineare ($\mathbf{Y} = A\mathbf{X}$)

Il secondo punto del teorema ci dice come si "aggiorna" la matrice di covarianza se moltiplichiamo il nostro vettore aleatorio per una matrice di costanti A.

Per comprendere questa formula ($G = ACA^T$), è utilissimo fare un parallelo con il caso unidimensionale (scalare). Se abbiamo una singola variabile aleatoria X con varianza σ_X^2, e definiamo una nuova variabile $Y = aX$ (dove a è un numero), sappiamo che la varianza scala con il quadrato della costante:

$$Var(Y) = a^2 Var(X) = a \cdot Var(X) \cdot a$$

Nel caso multidimensionale, X diventa un vettore $\mathbf{X}$, la costante a diventa una matrice A, e la varianza diventa la matrice di covarianza C. La regola di calcolo è la diretta generalizzazione del caso scalare:

$$Cov(\mathbf{Y}) = A \cdot Cov(\mathbf{X}) \cdot A^T$$

Si usa A^T (la trasposta di A) a destra invece di A per far tornare le dimensioni del prodotto tra matrici.

Dimostrazione:
Se indichiamo con μ_X il vettore delle medie di $\mathbf{X}$, la media di $\mathbf{Y}$ sarà $\mu_Y = A\mu_X$. Applicando la definizione di matrice di covarianza come valore atteso $\mathbb{E}[\cdot]$:

$$\begin{aligned} G &= \mathbb{E}[(\mathbf{Y} - \mu_Y)(\mathbf{Y} - \mu_Y)^T] \\ &= \mathbb{E}[(A\mathbf{X} - A\mu_X)(A\mathbf{X} - A\mu_X)^T] \\ &= \mathbb{E}[A(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^T A^T] \end{aligned}$$

Poiché A e A^T sono matrici di costanti, possono essere portate fuori dall'operatore di valore atteso:

$$\begin{aligned} G &= A \cdot \mathbb{E}[(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^T] \cdot A^T \\ &= A \cdot C \cdot A^T \end{aligned}$$

2.5 Correlazione

Siano X e Y due VA reali con varianza finita e strettamente positiva ($\mathbb{V}[X] > 0$ e $\mathbb{V}[Y] > 0$). Il coefficiente di correlazione (o correlazione lineare di Pearson) tra X e Y è definito come il rapporto tra la loro covarianza e il prodotto delle loro deviazioni standard:

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y} = \frac{cov(X,Y)}{\sqrt{\mathbb{V}[X]\mathbb{V}[Y]}}$$

Il coefficiente di correlazione è una misura adimensionale (priva di unità di misura) che quantifica il grado di dipendenza *lineare* tra due variabili.

Proprietà del Coefficiente di Correlazione

- **Limitatezza:** Per la disuguaglianza di Cauchy-Schwarz, il coefficiente è sempre compreso tra -1 e 1:
$$-1 \leq \rho_{X,Y} \leq 1$$
- **Correlazione perfetta:** $\rho_{X,Y} = 1$ (o -1) se e solo se esiste una relazione lineare perfetta tra X e Y, ovvero $Y = aX + b$ con $a > 0$ (o $a < 0$).
- Se X e Y sono indipendenti, allora $\rho_{X,Y} = 0$ (poiché $cov(X,Y) = 0$). In questo caso le variabili si dicono **scorrelate**.

N.B.: Come per la covarianza, se $\rho_{X,Y} = 0$ (variabili scorrelate) non è detto che X e Y siano indipendenti. L'assenza di correlazione implica solo l'assenza di un legame *lineare*, ma potrebbe esistere un forte legame di tipo non lineare (ad esempio $Y = X^2$).

2.5.1 Matrice di Correlazione

Sia $\mathbf{X} = [X_1, ..., X_n]$ un vettore aleatorio in $\mathbb{R}^n$ dove ogni componente ha varianza finita non nulla. La matrice di correlazione di $\mathbf{X}$ è la matrice quadrata $n \times n$ il cui termine generale è $\rho_{i,j} = \rho_{X_i,X_j}$:

$$R = \begin{bmatrix} \rho_{1,1} & \rho_{1,2} & \cdots & \rho_{1,n} \\ \rho_{2,1} & \rho_{2,2} & \cdots & \rho_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{n,1} & \rho_{n,2} & \cdots & \rho_{n,n} \end{bmatrix} = \begin{bmatrix} 1 & \rho_{X_1,X_2} & \cdots & \rho_{X_1,X_n} \\ \rho_{X_2,X_1} & 1 & \cdots & \rho_{X_2,X_n} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{X_n,X_1} & \rho_{X_n,X_2} & \cdots & 1 \end{bmatrix}$$

Poiché la correlazione di una variabile con se stessa è esattamente 1 ($\rho_{X_i,X_i} = \frac{cov(X_i,X_i)}{Var(X_i)} = 1$), la matrice di correlazione ha sempre tutti 1 sulla diagonale principale. Inoltre, così come la matrice di covarianza, anche la matrice di correlazione è **simmetrica** (poiché $\rho_{X_i,X_j} = \rho_{X_j,X_i}$) e semidefinita positiva.

2.6 Distribuzione di una trasformazione di un Vettore Aleatorio

Questa è la generalizzazione di quanto visto nel capitolo precedente.

Ora focalizziamoci sulle trasformazioni di vettori aleatori a valori in $\mathbb{R}^n$. Sia $g : \mathbb{R}^n \to \mathbb{R}^n$ una funzione Borel-misurabile. Dato $\mathbf{X} = [X_1, ..., X_n]$ con densità f, qual'è la densità di $\mathbf{Y} = g(\mathbf{X})$?
Ricordiamo che se g è una funzione differenziabile da un insieme aperto G in $\mathbb{R}^n$ a $\mathbb{R}^n$, la sua matrice jacobiana $J_g(x)$ nel punto $x \in G$ è:

$$J_g(x) = \frac{\partial g}{\partial x}(x)$$

Ovvero il termine ij-esimo è $J_g(x)_{ij} = \frac{\partial g_i}{\partial x_j}$, dove $g = [g_1, ..., g_n]$. Lo jacobiano di g nel punto x è il determinante della matrice jacobiana $\det(J_g(x))$. Se lo Jacobiano $\neq 0$ allora g è invertibile in un intorno di x e lo jacobiano dell'inversa $\det(J_{g^{-1}}(x))$ nel punto $y = g(x)$ è l'inverso dello jacobiano di g in x.

Formula di Trasformazione di Jacobi

Sia G un insieme aperto in $\mathbb{R}^n$ e sia $g : G \to \mathbb{R}^n$ continuamente differenziabile. Supponiamo che g sia iniettiva (one-to-one) su G e che il suo Jacobiano non si annulli mai. Allora per f misurabile e tale che il prodotto $f\mathbb{1}_{g(G)}$ sia positivo e integrabile rispetto alla misura di Lebesgue:

$$\int_{g(G)} f(y)d\mathbf{y} = \int_G f(g(x))|\det(J_g(x))|dx$$

dove $g(G) = \{y \in \mathbb{R}^n : \exists x \in G t.c. g(x) = y\}$

Questo teorema è una componente fondamentale dell'analisi vettoriale e della probabilità continua. Ecco perché funziona e cosa significa:

- **Il significato di $d\mathbf{y}$ e $d\mathbf{x}$:** Negli integrali multipli, $d\mathbf{x} = dx_1 dx_2 \dots dx_n$ rappresenta un volume infinitesimale nello spazio di partenza, mentre $d\mathbf{y}$ è un volume infinitesimale nello spazio di arrivo.
- **Il ruolo del determinante Jacobiano:** Quando applichiamo la funzione g, deformiamo lo spazio. Un cubetto infinitesimale di volume $d\mathbf{x}$ nello spazio X viene trasformato in un parallelepipedo nello spazio Y. Il volume di questo nuovo solido non è uguale a quello di partenza, ma è scalato esattamente di un fattore pari al valore assoluto del determinante Jacobiano:

$$d\mathbf{y} = |\det(J_g(\mathbf{x}))|\, d\mathbf{x}$$

- **Il valore assoluto:** Il determinante della matrice Jacobiana può essere negativo (il che indica un cambio di "orientamento" degli assi, come una riflessione a specchio). Poiché i volumi e le probabilità non possono mai essere negativi, prendiamo sempre il valore assoluto $|\det(J_g(\mathbf{x}))|$.

Teorema del Cambio di Variabile Multidimensionale

Sia $\mathbf{X} = [X_1, ..., X_n]$ un vettore aleatorio con densità congiunta $f_{\mathbf{X}}$. Sia $g : \mathbb{R}^n \to \mathbb{R}^n$ continuamente differenziabile e iniettiva, con jacobiano mai nullo. Allora $\mathbf{Y} = g(\mathbf{X})$ ha densità:

$$f_Y(\mathbf{y}) = \begin{cases} f_X(g^{-1}(\mathbf{y})) \cdot \left|\det(J_{g^{-1}}(\mathbf{y}))\right| & \text{se } \mathbf{y} \in g(G) \\ 0 & \text{altrimenti} \end{cases}$$

Il testo poneva la domanda: *Dato $\mathbf{X}$ con densità f_X, qual è la densità di $\mathbf{Y} = g(\mathbf{X})$?*

Grazie alla formula di Jacobi appena vista, possiamo ricavare direttamente la densità del nuovo vettore aleatorio $\mathbf{Y}$. Affinché la probabilità si conservi ($P(\mathbf{X} \in G) = P(\mathbf{Y} \in g(G))$), la densità f_Y nel punto $\mathbf{y}$ deve compensare la deformazione del volume.

La formula per la densità di $\mathbf{Y}$ diventa quindi:

$$f_Y(\mathbf{y}) = \begin{cases} f_X(g^{-1}(\mathbf{y})) \cdot \left|\det(J_{g^{-1}}(\mathbf{y}))\right| & \text{se } \mathbf{y} \in g(G) \\ 0 & \text{altrimenti} \end{cases}$$

Oppure, equivalentemente, usando lo Jacobiano della funzione diretta valutato in $\mathbf{x} = g^{-1}(\mathbf{y})$:

$$f_Y(\mathbf{y}) = f_X(\mathbf{x}) \cdot \frac{1}{|\det(J_g(\mathbf{x}))|}$$

Questa divisione per il determinante esprime esattamente il fatto che se la trasformazione g "dilata" lo spazio (determinante grande), la probabilità si "spalma" su un'area maggiore, e quindi la *densità* in quel punto deve diminuire.

Possiamo trattare anche il caso in cui g non è iniettiva ma comunque regolare.

Teorema del Cambio di Variabile Multidimensionale (funzioni non intiettive)

Sia $\mathcal{S} \in \mathcal{B}^n$ partizionato in sottoinsiemi disgiunti $S_1, ..., S_m$ tali che $\bigcup_{i=0}^{m} S_i = \mathcal{S}$ e tali che $m_n(S_0) = 0$ e che per ogni $i = 1, ..., m$, la funzione $g : S_i \to \mathbb{R}^n$ sia iniettiva e continuamente differenziabile con jacobiano mai nullo. Sia $\mathbf{Y} = g(\mathbf{X})$, dove $\mathbf{X} = [X_1, ..., X_n]$ è un vettore aleatorio a valori in $\mathbb{R}^n$ con valori in $\mathcal{S}$ e densità $f_{\mathbf{X}}$. Allora $\mathbf{Y}$ ha una densità data da:

$$f_{\mathbf{Y}} = \sum_{i=1}^{m} f_{\mathbf{X}}(g_i^{-1}(y)) |\det J_{g_i^{-1}}(y)|$$

dove $g_i^{-1} : g(S_i) \to S_i$ denota la mappa inversa e $J_{g_i^{-1}}$ è la corrispondente matrice jacobiana.

Riassumendo, se abbiamo un vettore aleatorio $\mathbf{X}$ a cui applichiamo una trasformazione g, ottenendo una nuovo vettore aleatorio $Y = g(\mathbf{X})$, per trovare la PDF $f_{\mathbf{Y}}$:

1. Sostituzione $f_{\mathbf{X}}(g^{-1}(y))$: prendiamo la "vecchia" densità $f_{\mathbf{X}}(x)$ sostituendo x con la trasformazione inversa $g^{-1}(y)$. Se vuoi conoscere la massa di probabilità intorno a $Y = 5$, devi andare a guardare quanta ce n'era intorno al valore di X prima che gli venisse applicata la trasformazione che ha generato quel 5.
2. Correzione $|\det(J_{g^{-1}}(y))|$: moltiplica per il valore assoluto dello jacobiano dell'inversa. Questo è il fattore di scala che assicura che la deformazione dello spazio non crei o distrugga probabilità.

Se la trasformazione non è iniettiva, il corollario ci dice che ci basta partizionare il dominio della trasformazione, applicare la formula del cambio di variabile a livello locale (dove la funzione è iniettiva) e poi sommare i contributi.