Geometria della conditional expectation: spazi di Hilbert, spazi di Banach e spazi L^p

Tommaso Zeri

February 2026

Contents

1 Spazi L^2 e di Hilbert **2**
1.1 Inner Product . . . 2
1.2 Norma in L^2 . . . 2

2 Spazi di Hilbert **4**
2.1 Ortogonalità . . . 5
2.2 Sottospazi di $\mathcal{H}$ . . . 6
2.3 Distanza . . . 7
2.4 Operatore di Proiezione . . . 8

3 Valore Atteso Condizionato **12**
3.1 Valore atteso condizionato di Y dato l'evento $\{X = x_j\}$ . . . 12
3.2 Valore atteso condizionato di Y data X discreta . . . 13
3.2.1 σ-algebra generata da una variabile aleatoria . . . 15
3.3 Valore atteso condizionato di Y data X (Caso L^2 e Generale) . . . 16
3.4 Valore atteso condizionato rispetto a una sub-σ-algebra . . . 18
3.5 Il passaggio da L^2 a L^1 . . . 19
3.6 Disuaguaglianze Fondamentali . . . 21
3.6.1 Disuguaglianza di Jensen (Versione Condizionata) . . . 21
3.6.2 Disuguaglianza di Hölder . . . 21
3.6.3 Disuguaglianza di Minkowski . . . 22
3.7 La norma in L^p e la geometria degli spazi . . . 22
3.8 MCT, Lemma di Fatou e DCT condizionati . . . 23

1 Spazi L^2 e di Hilbert

Supponiamo che sia dato uno spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$. Indichiamo con L^2 tutte le (classi di equivalenza per l'uguaglianza A.S. di) variabili aleatorie X tali che $\mathbb{E}[|X|^2] < \infty$. D'ora in poi identificheremo tutte le le VA $X, Y \in L^2$ (che sono uguali A.S.) e le considereremo come rappresentazioni della stessa VA. Questo ha come conseguenza che se $\mathbb{E}[X^2] = 0$ allora $X = 0$.

1.1 Inner Product

Definiamo un inner product in L^2 nel seguente modo: per ogni $X, Y \in L^2$:

$$\langle X, Y \rangle = \mathbb{E}[XY]$$

Notiamo che per la disuguaglianza di Cauchy-Schwartz:

$$|\mathbb{E}[XY]| \leq (\mathbb{E}[X^2])^{1/2}(\mathbb{E}[Y^2])^{1/2} < \infty$$

Abbiamo già visto che L^2 è uno spazio lineare: se $X, Y \in L^2$ e α, β sono costanti, allora anche $\alpha X + \beta Y \in L^2$. Inoltre l'inner product è lineare in ogni sua componente:

$$\langle \alpha X + \beta Y, Z \rangle = \alpha \langle X, Z \rangle + \beta \langle Y, Z \rangle$$

Infine osserviamo che $\langle X, X \rangle \geq 0$ e $\langle X, X \rangle = 0$ se e solo se $X = 0$.

1.2 Norma in L^2

Una norma in L^2 è definita come:

$$\|X\| = \langle X, X \rangle^{1/2} = (\mathbb{E}[X^2])^{1/2}$$

Notiamo che per la bilinearità e per la disuguaglianza di Cauchy-Schwartz (per maggiorare il termine misto $\mathbb{E}[XY] \leq \|X\|\|Y\|$ abbiamo:

$$\|X + Y\|^2 = \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2] \leq \|X\|^2 + 2\|X\|\|Y\| + \|Y\|^2 = (\|X\| + \|Y\|)^2$$

Applicando la radice quadrata a entrambi i membri, i quadrati si semplificano e così otteniamo la **Disuguaglianza di Minkowski**:

$$\|X + Y\| \leq \|X\| + \|Y\|$$

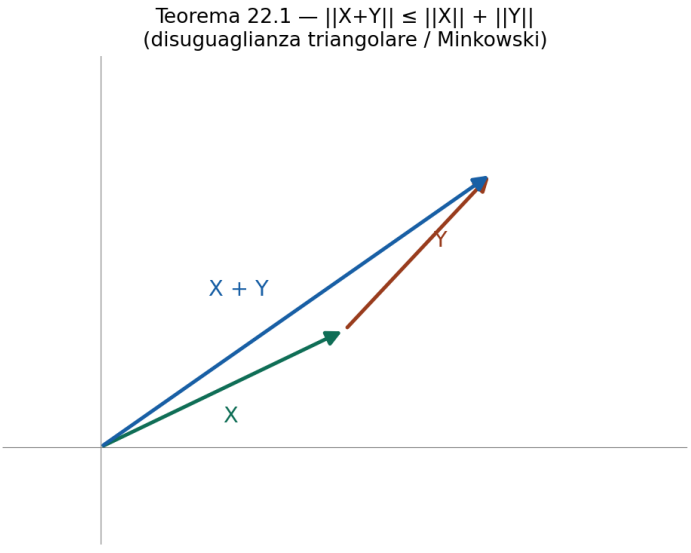


Figure 1: Il vettore $X + Y$ è la diagonale del percorso $X \to Y$: la sua lunghezza non può mai superare la somma delle lunghezze dei due lati, $\|X + Y\| \leq \|X\| + \|Y\|$.

L^2 è uno spazio lineare normato

L^2 è uno spazio lineare normato dotato di inner product $\langle \cdot, \cdot \rangle$. Inoltre, si ha:

$$\| \cdot \| = \langle \cdot, \cdot \rangle$$

Ora vogliamo dimostrare che L^2 è uno spazio lineare normato completo; ovvero, se X_n è una successione di VA che è di Cauchy, allora esiste un limite in L^2.

Successione di Cauchy

In matematica, una **successione di Cauchy** (o successione fondamentale) è una successione in cui i termini si avvicinano arbitrariamente tra loro man mano che si procede all'infinito.
Definizione Formale
Sia X uno spazio vettoriale dotato di una norma $\| \cdot \|$. Una successione $\{x_n\}_{n \in \mathbb{N}}$ a valori in X si dice di Cauchy se, per ogni $\epsilon > 0$, esiste un indice $N \in \mathbb{N}$ tale per cui, per ogni $n, m > N$, si ha:

$$\|x_n - x_m\| < \epsilon$$

La particolarità di questa definizione è che *non richiede di conoscere il limite* a cui tende la successione. Non stiamo misurando la distanza da un punto di arrivo finale, ma stiamo verificando che la distanza tra *due termini qualsiasi* della coda della successione diventi piccola a piacere.
Il ruolo della Completezza
È sempre vero che una successione convergente è di Cauchy. Tuttavia, il viceversa dipende dallo spazio in cui ci troviamo:

- Se lo spazio ha dei "buchi" (come l'insieme dei numeri razionali $\mathbb{Q}$), una successione di Cauchy potrebbe non convergere a un elemento di quello spazio.
- Se in uno spazio normato *tutte* le successioni di Cauchy convergono a un elemento dello spazio stesso, lo spazio si dice **completo**.

Uno spazio vettoriale normato e completo prende il nome di **Spazio di Banach**. Se la norma deriva da un prodotto scalare (come per lo spazio L^2 delle variabili aleatorie), prende il nome speciale di **Spazio di Hilbert**.

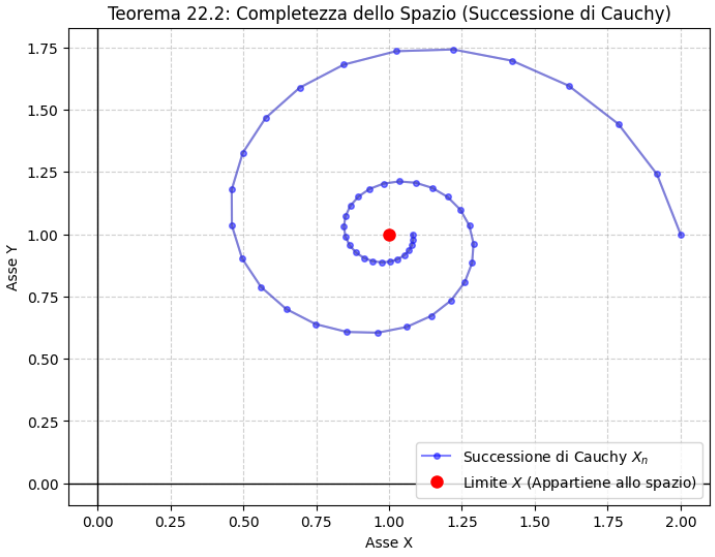


Figure 2: Successione di Cauchy

L^2 è uno spazio completo

L^2 è uno spazio lineare normato completo

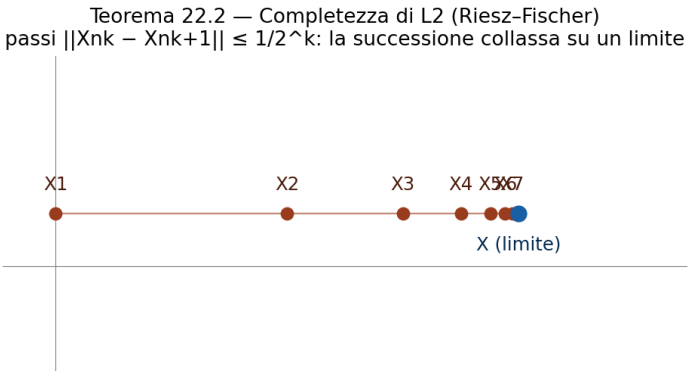


Figure 3: La sottosuccessione $X_1, X_2, X_3, \ldots$ si muove a passi sempre più piccoli ($\leq 1/2^k$) e per questo è costretta a collassare su un punto limite X, che appartiene ancora a L^2.

2 Spazi di Hilbert

Uno spazio di Hilbert $\mathcal{H}$ è uno spazio lineare normato completo con un inner product che soddisfa:

$$\langle x, x \rangle^{1/2} = \|x\| \quad \forall x \in \mathcal{H}$$

L^2 e $\mathcal{H}$

L^2 è uno spazio di Hilbert.

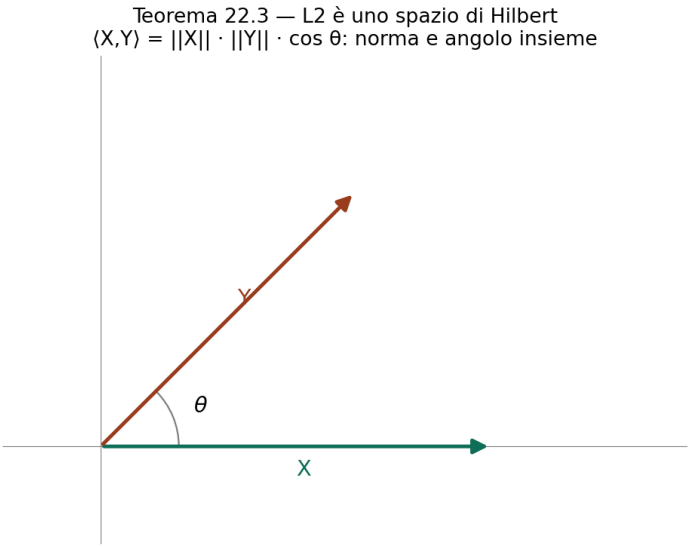


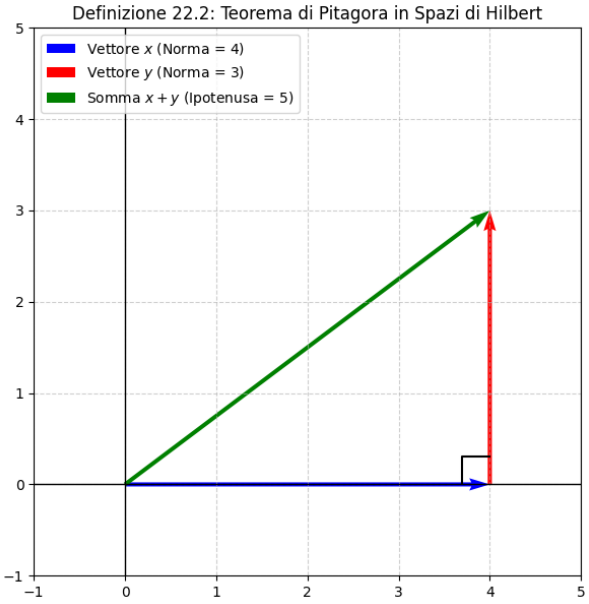
Figure 4: Il prodotto scalare $\langle X, Y \rangle = \|X\| \, \|Y\| \cos\theta$ racchiude in sé sia la lunghezza dei vettori sia l'angolo tra loro: è questa struttura in più, rispetto a una semplice norma, che rende L^2 uno spazio di Hilbert.

D'ora in poi non parleremo più di VA e valori attesi, ma di vettori in un generico spazio di Hilbert $\mathcal{H}$.

2.1 Ortogonalità

Due vettori $x, y \in \mathcal{H}$ sono ortogonali se $\langle x, y \rangle = 0$.
Un vettore x è ortogonale ad un insieme di vettori Γ se $\langle x, y \rangle = 0 \quad \forall y \in \Gamma$.

Osserviamo che se $\langle x, y \rangle = 0$, allora $\|x + y\|^2 = \|x\|^2 + \|y\|^2$, che è la versione di Hilbert del Teorema di Pitagora.



Nel nostro spazio probabilistico L^2 ciò significa che:

$$\langle X, Y \rangle = 0 \implies \mathbb{E}[XY] = 0 \implies \text{le VA sono ortogonali}$$

Ortogonalità vs Incorrelazione
Dire che due variabili aleatorie sono ortogonali non equivale automaticamente a dire che sono *incorrelate*. Sapendo che la covarianza è definita come:

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

se X e Y sono ortogonali ($\mathbb{E}[XY] = 0$), la loro covarianza diventa $\text{Cov}(X, Y) = -\mathbb{E}[X]\mathbb{E}[Y]$. Di conseguenza, due variabili ortogonali sono anche incorrelate se e solo se almeno una delle due ha valore atteso nullo ($\mathbb{E}[X] = 0$ oppure $\mathbb{E}[Y] = 0$).

Continuità dell'inner product

Se $x_n \to x$ e $y_n \to y$ in $\mathcal{H}$, allora $\langle x_n, y_n \rangle \to \langle x, y \rangle$ in $\mathbb{R}$. E quindi anche $\|x_n\| \to \|x\|$.

Questo teorema ci garantisce che il prodotto scalare (e di conseguenza la norma) è una **funzione continua**. In termini di calcolo, significa che l'operazione di limite e il prodotto scalare "commutano", ovvero possiamo portare il limite all'interno delle parentesi:

$$\lim_{n\to\infty} \langle x_n, y_n \rangle = \left\langle \lim_{n\to\infty} x_n, \lim_{n\to\infty} y_n \right\rangle = \langle x, y \rangle$$

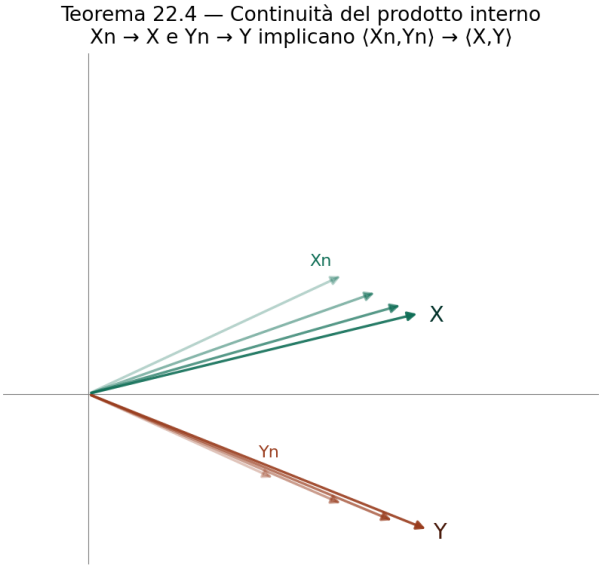


Figure 5: Se $X_n \to X$ e $Y_n \to Y$, allora anche $\langle X_n, Y_n\rangle \to \langle X, Y\rangle$: non ci sono salti improvvisi nel passaggio al limite.

2.2 Sottospazi di $\mathcal{H}$

Un sottoinsieme $\mathcal{L}$ si $\mathcal{H}$ è un sottospazio se è lineare (se $x, y \in \mathcal{L}$ allora $\alpha x + \beta y \in \mathcal{L}$) e se è chiuso (se $\{x_n\}_{n\geq 1}$ converge ad x in $\mathcal{H}$, allora $x \in \mathcal{L}$).

Complemento ortogonale

Sia Γ un insieme di vettori. Indichiamo com $\Gamma^\perp$ il complemento ortogonale, ovvero l'insieme di tutti i vettori che sono ortogonali a tutti i vettori in Γ. Abbiamo dunque che $\Gamma^\perp$ è un sottospazio di $\mathcal{H}$.

Per dimostrare che è un sottospazio, dobbiamo verificare che sia chiuso rispetto alla combinazione lineare. Siano $x_1, x_2 \in \Gamma^\perp$ e siano α, β due scalari. Dobbiamo verificare che $(\alpha x_1 + \beta x_2) \in \Gamma^\perp$. Prendiamo un generico $y \in \Gamma$ e calcoliamo il prodotto scalare sfruttando la linearità:

$$\langle \alpha x_1 + \beta x_2, y\rangle = \alpha\langle x_1, y\rangle + \beta\langle x_2, y\rangle$$

Poiché x_1 e x_2 appartengono a $\Gamma^\perp$, sappiamo per definizione che $\langle x_1, y\rangle = 0$ e $\langle x_2, y\rangle = 0$. Quindi:

$$\alpha(0) + \beta(0) = 0$$

Dato che questo vale per ogni $y \in \Gamma$, concludiamo che la combinazione lineare $(\alpha x_1 + \beta x_2)$ appartiene a $\Gamma^\perp$.

Perché è "chiuso"?
Il fatto che $\Gamma^\perp$ sia un sottospazio *chiuso* (cioè che contenga tutti i suoi punti di accumulazione) deriva direttamente dal teorema sulla **continuità del prodotto scalare**. Se prendiamo una successione $x_n \in \Gamma^\perp$ tale che $x_n \to x$, portando il limite dentro al prodotto scalare avremo che $\langle x, y\rangle = \lim_{n\to\infty}\langle x_n, y\rangle = 0$, garantendo che anche il limite x si trovi in $\Gamma^\perp$.

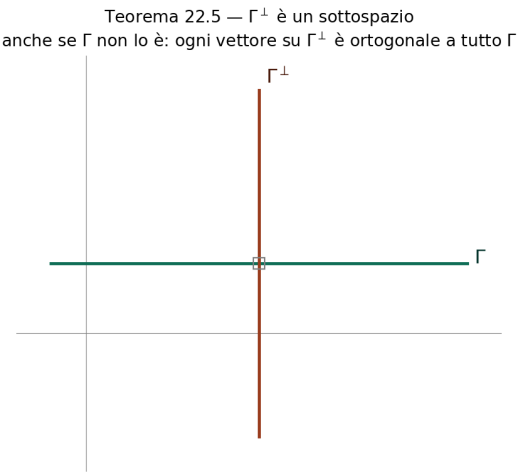


Figure 6: Anche se l'insieme di partenza Γ (la retta orizzontale) non è un sottospazio, il suo ortogonale $\Gamma^\perp$ (la retta verticale, fatta di tutti i vettori perpendicolari a Γ) lo è sempre — lineare e chiuso.

2.3 Distanza

Per un sottospazio $\mathcal{L}$ di $\mathcal{H}$, sia

$$d(x, \mathcal{L}) = \inf\{\|x - y\| : y \in \mathcal{L}\}$$

la distanza da $x \in \mathcal{H}$ a $\mathcal{L}$.

Distanza tra un punto e un sottospazio

La formula rigorosa per definire la distanza tra un vettore x e un intero sottospazio $\mathcal{L}$ è:

$$d(x, \mathcal{L}) = \inf\{\|x - y\| : y \in \mathcal{L}\}$$

Scomposizione della formula:

- $d(x, \mathcal{L})$: indica la distanza tra il punto fissato x e l'insieme $\mathcal{L}$.
- $\|x-y\|$: è la distanza tra x e un generico vettore y. Geometricamente, è la norma (lunghezza) del vettore differenza.
- $\{\cdots : y \in \mathcal{L}\}$: indica l'insieme di tutte le possibili distanze che si ottengono facendo variare y in tutti i modi possibili all'interno del sottospazio $\mathcal{L}$.
- inf **(Estremo inferiore)**: l'operatore seleziona il limite inferiore di questo insieme di distanze.

Perché si usa inf **e non** min **(minimo)?**
In analisi matematica, l'estremo inferiore (inf) *esiste sempre* per un insieme di numeri reali limitato inferiormente (e le distanze sono sempre ≥ 0). Il minimo (min), invece, esiste solo se quel valore viene effettivamente "toccato" da un elemento dell'insieme.
Se un generico insieme non è chiuso (immagina un cerchio senza il bordo), le distanze possono avvicinarsi indefinitamente a un valore senza mai raggiungerlo: in quel caso avremmo un inf, ma non un min. Tuttavia, il **Teorema della Proiezione** ci garantisce che, poiché $\mathcal{L}$ è un sottospazio **chiuso**, questo valore minimo viene effettivamente raggiunto da un vettore unico (la proiezione ortogonale). In questo caso specifico, l'inf diventa a tutti gli effetti un min.

Notiamo che se $\mathcal{L}$ è un sottospazio, allora $x \in \mathcal{L}$ se e solo se $d(x, \mathcal{L}) = 0$, ovvero la distanza tra x e $\mathcal{L}$ è 0.

Teorema della Proiezione (o della Migliore Approssimazione)

Sia $\mathcal{L}$ un sottospazio **chiuso** di uno spazio di Hilbert $\mathcal{H}$ e sia $x \in \mathcal{H}$. Allora esiste un unico vettore $y \in \mathcal{L}$ (chiamato *proiezione ortogonale* di x su $\mathcal{L}$) tale che minimizza la distanza da x:

$$\|x - y\| = \inf_{z \in \mathcal{L}} \|x - z\| = d(x, \mathcal{L})$$

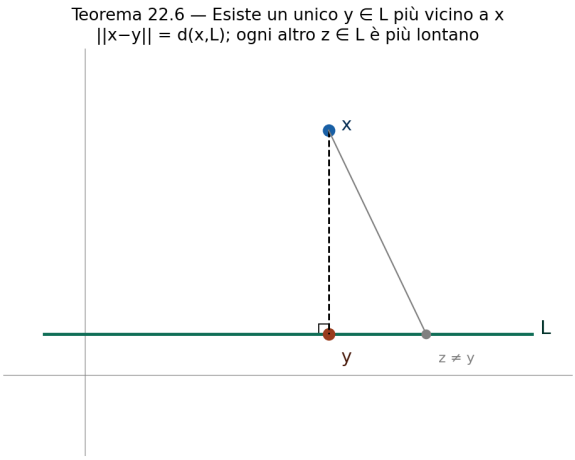


Figure 7: Dato un punto x fuori dal sottospazio L, esiste un unico $y \in L$ che minimizza la distanza: $\|x - y\| = d(x, L)$. Qualunque altro punto $z \in L$ è strettamente più lontano.

Caratterizzazione tramite Ortogonalità
Il vettore $y \in \mathcal{L}$ è la proiezione ortogonale di x se e solo se l'errore di approssimazione $(x-y)$ è ortogonale a tutto il sottospazio $\mathcal{L}$. Ovvero:

$$\langle x - y, z \rangle = 0 \quad \forall z \in \mathcal{L}$$

Questo equivale a dire che l'errore $(x - y) \in \mathcal{L}^{\perp}$.

Significato Geometrico e Pratico
Geometricamente, stiamo tracciando l'altezza (la perpendicolare) dal punto x al "piano" $\mathcal{L}$. Il punto di intersezione y è il punto di $\mathcal{L}$ più vicino a x. Questo vettore y rappresenta la **migliore approssimazione** possibile dell'elemento x utilizzando solo gli elementi a disposizione nel sottospazio $\mathcal{L}$.

L'operatore di proiezione
Grazie a questo teorema, possiamo definire un operatore $\Pi : \mathcal{H} \to \mathcal{L}$ che associa ad ogni x la sua unica proiezione y. Di conseguenza, ogni vettore $x \in \mathcal{H}$ può essere scomposto in modo unico come:

$$x = y + (x - y) = \Pi(x) + x^{\perp}$$

dove $\Pi(x) \in \mathcal{L}$ e $x^{\perp} \in \mathcal{L}^{\perp}$. Questa si chiama *scomposizione ortogonale* dello spazio $\mathcal{H}$.

2.4 Operatore di Proiezione

Fissiamo uno spazio di Hilbert $\mathcal{H}$ e un sottospazio (chiuso e lineare) $\mathcal{L}$. La proiezione di un vettore $x \in \mathcal{H}$ su $\mathcal{L}$ consiste nel prendere l'unico vettore $y \in \mathcal{L}$ che è più vicino a x.
Indichiamo l'operatore di proiezione con Π.

Proprietà dell'operatore di proiezione

L'operatore di proiezione ortogonale Π di uno spazio di Hilbert $\mathcal{H}$ su un sottospazio chiuso $\mathcal{L}$ soddisfa le seguenti proprietà fondamentali:

1. Π **è idempotente:** $\Pi^2 = \Pi$
   Significato geometrico: Applicare la proiezione due volte equivale ad applicarla una volta sola. Se proietti un vettore sul piano $\mathcal{L}$, il nuovo vettore si trova già su quel piano; cercare di proiettarlo di nuovo non lo sposterà. In simboli: $\Pi(\Pi(x)) = \Pi(x)$.
2. **Azione sui sottospazi chiave:**
   $\Pi(x) = x \quad$ per $x \in \mathcal{L}$
   $\Pi(x) = 0 \quad$ per $x \in \mathcal{L}^\perp$
   Significato geometrico: L'operatore agisce come funzione identità per i vettori che appartengono già a $\mathcal{L}$ (sono già perfetti, non c'è nulla da approssimare). Al contrario, annulla completamente i vettori che appartengono al complemento ortogonale $\mathcal{L}^\perp$, poiché questi non hanno alcuna "ombra" proiettata su $\mathcal{L}$ (sono a 90°).
3. **Ortogonalità del residuo (o errore):**
   Per ogni $x \in \mathcal{H}$, il vettore $(x - \Pi(x))$ è ortogonale a $\mathcal{L}$.
   Significato geometrico: È il cuore del Teorema della Proiezione. Il vettore originale x viene diviso perfettamente in due parti ortogonali tra loro:

$$x = \underbrace{\Pi(x)}_{\in \mathcal{L}} + \underbrace{(x - \Pi(x))}_{\in \mathcal{L}^\perp}$$

   La prima è la migliore approssimazione, la seconda è l'errore commesso.

Nota (Linearità): Oltre a queste, l'operatore Π su un sottospazio è sempre un operatore **lineare**, ovvero $\Pi(\alpha x + \beta y) = \alpha\Pi(x) + \beta\Pi(y)$.

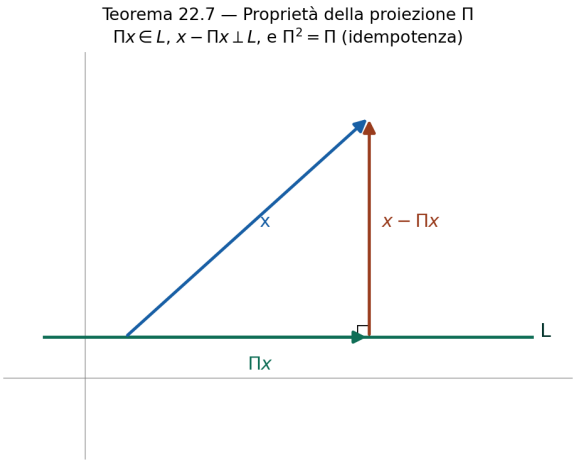


Figure 8: Πx cade dentro L, il residuo $x - \Pi x$ è ortogonale a tutto L, e proiettare due volte di seguito equivale a proiettare una sola volta: $\Pi^2 = \Pi$ (idempotenza).

Corollario: Decomposizione Ortogonale

Sia $\Pi_\mathcal{L}$ l'operatore di proiezione ortogonale di $\mathcal{H}$ su un sottospazio chiuso $\mathcal{L}$. Allora l'identità:

$$x = \Pi_\mathcal{L}(x) + (x - \Pi_\mathcal{L}(x))$$

è una **rappresentazione unica** di x come somma di un vettore in $\mathcal{L}$ e uno in $\mathcal{L}^\perp$.

Proiezione sul complemento ortogonale
Il termine residuo (l'errore di approssimazione) $(x - \Pi_{\mathcal{L}}(x))$ è esattamente la proiezione ortogonale di x sul sottospazio $\mathcal{L}^{\perp}$. Possiamo quindi definire un nuovo operatore $\Pi_{\mathcal{L}^{\perp}}(x) = x - \Pi_{\mathcal{L}}(x)$, riscrivendo in modo elegante la scomposizione come:

$$x = \Pi_{\mathcal{L}}(x) + \Pi_{\mathcal{L}^{\perp}}(x)$$

Conseguenza (Teorema di Pitagora)
Poiché per definizione $\Pi_{\mathcal{L}}(x) \perp \Pi_{\mathcal{L}^{\perp}}(x)$, possiamo applicare il Teorema di Pitagora calcolando la norma al quadrato di entrambi i membri:

$$\|x\|^2 = \|\Pi_{\mathcal{L}}(x)\|^2 + \|x - \Pi_{\mathcal{L}}(x)\|^2$$

Significato pratico: La "lunghezza" totale del vettore è la somma esatta della lunghezza della sua approssimazione e della lunghezza dell'errore commesso. In probabilità, questa è esattamente la formula della **scomposizione della varianza**.

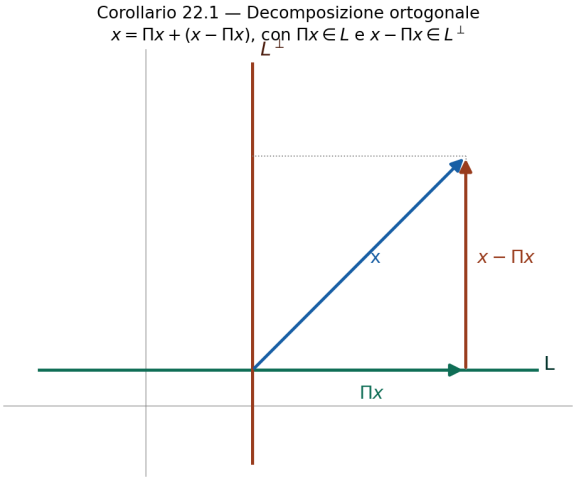


Figure 9: Ogni x si scompone in modo unico nella somma di una componente in L (Πx) e una in $L^{\perp}$ ($x - \Pi x$), da cui segue anche che $(L^{\perp})^{\perp} = L$.

Corollario: Altre proprietà dell'operatore di proiezione

Sia $\Pi_{\mathcal{L}}$ l'operatore di proiezione ortogonale di uno spazio di Hilbert $\mathcal{H}$ su un sottospazio chiuso $\mathcal{L}$. Allora valgono le seguenti proprietà:

1. **Simmetria (o Operatore Autoaggiunto):**

$$\langle \Pi_{\mathcal{L}}(x), y \rangle = \langle x, \Pi_{\mathcal{L}}(y) \rangle = \langle \Pi_{\mathcal{L}}(x), \Pi_{\mathcal{L}}(y) \rangle$$

Significato analitico: L'operatore di proiezione può essere "spostato" da un argomento all'altro del prodotto scalare senza alterare il risultato.
Perché è vero? Ricordando la scomposizione ortogonale $y = \Pi_{\mathcal{L}}(y) + y^{\perp}$, se calcoliamo il prodotto scalare del primo termine otteniamo:

$$\langle \Pi_{\mathcal{L}}(x), y \rangle = \langle \Pi_{\mathcal{L}}(x), \Pi_{\mathcal{L}}(y) + y^{\perp} \rangle = \langle \Pi_{\mathcal{L}}(x), \Pi_{\mathcal{L}}(y) \rangle + \underbrace{\langle \Pi_{\mathcal{L}}(x), y^{\perp} \rangle}_{=0}$$

Il termine incrociato si annulla perché $\Pi_{\mathcal{L}}(x) \in \mathcal{L}$ e $y^{\perp} \in \mathcal{L}^{\perp}$. Facendo lo stesso ragionamento per $\langle x, \Pi_{\mathcal{L}}(y) \rangle$ si arriva all'identico risultato centrale.

2. **Linearità:**
Per ogni coppia di vettori $x, y \in \mathcal{H}$ e di scalari α, β:

$$\Pi_{\mathcal{L}}(\alpha x + \beta y) = \alpha \Pi_{\mathcal{L}}(x) + \beta \Pi_{\mathcal{L}}(y)$$

Significato geometrico: Proiettare prima i vettori e poi combinarli produce lo stesso risultato che combinarli prima e proiettare il vettore finale. L'ombra di una somma è la somma delle ombre.

Applicazione lineare

Sia T un'applicazione da $\mathcal{H}$ su un sottospazio $\mathcal{L}$. Supponiamo che $x - T(x)$ sia ortogonale a $\mathcal{L} \quad \forall x \in \mathcal{H}$. Allora $T = \Pi_{\mathcal{L}}$, l'operatore di proiezione sul sottospazio $\mathcal{L}$.

Questo teorema ci dice come "verificare" se abbiamo calcolato correttamente una proiezione. Se in un esercizio "indoviniamo" o proponiamo una certa formula $T(x)$ e vogliamo assicurarci che sia la proiezione ortogonale su $\mathcal{L}$, ci basta controllare due cose:

1. Che il risultato $T(x)$ stia in $\mathcal{L}$.
2. Che il residuo $(x - T(x))$ sia ortogonale a tutti gli elementi di $\mathcal{L}$.

Se entrambe le condizioni sono soddisfatte, allora $T(x)$ è senza dubbio la proiezione ortogonale.

3 Valore Atteso Condizionato

Siano X e Y due VA. Con Y a valori in $\mathbb{R}$ e X che assume solo una quantitità numerabile di valori $\{x_1, ..., x_n, ...\}$. Supponiamo di sapere che si è verificato l'evento $\{X = x_j\}$. Il valore atteso di Y può cambiare in base a questa conoscenza.

3.1 Valore atteso condizionato di Y dato l'evento $\{X = x_j\}$

Il concetto di **valore atteso condizionato** rispetto a un singolo evento è il primo passo per capire matematicamente come la scoperta di una nuova informazione aggiorni le nostre stime.

Sia X una variabile aleatoria discreta, a valori in un insieme numerabile $\{x_1, \dots, x_n, \dots\}$, e sia Y una variabile aleatoria a valori reali in $\mathbb{R}$. Fissiamo un evento specifico: supponiamo di aver appena osservato (o di ipotizzare) che X abbia assunto esattamente il valore x_j. Affinché abbia senso condizionare rispetto a questo evento, dobbiamo assicurarci che non sia impossibile, richiedendo che $\mathbb{P}(X = x_j) > 0$.

Sotto questa ipotesi, il valore atteso condizionato di Y dato l'evento $\{X = x_j\}$ è definito rigorosamente come:

$$\mathbb{E}[Y|X = x_j] = \mathbb{E}_{\mathbb{Q}}[Y]$$

Il cambio di misura di probabilità
Il cuore di questa definizione risiede nell'introduzione di $\mathbb{Q}$, che rappresenta una *nuova* misura di probabilità. Per un qualsiasi evento Λ, la nuova probabilità $\mathbb{Q}(\Lambda)$ è definita tramite la probabilità condizionata classica introdotta da Kolmogorov:

$$\mathbb{Q}(\Lambda) = \mathbb{P}(\Lambda|X = x_j) = \frac{\mathbb{P}(\Lambda \cap \{X = x_j\})}{\mathbb{P}(X = x_j)}$$

Intuitivamente, sapere che $X = x_j$ si è verificato cambia il nostro "universo" di riferimento. Tutti gli esiti dello spazio campionario in cui $X \neq x_j$ vengono immediatamente scartati: la loro probabilità sotto la nuova misura $\mathbb{Q}$ crolla a zero. Viceversa, le probabilità di tutti gli eventi compatibili con $X = x_j$ vengono "riproporzionate", ovvero divise per il fattore di scala $\mathbb{P}(X = x_j)$, così che la probabilità totale del nuovo universo torni a sommare a 1.

Di conseguenza, calcolare il valore atteso condizionato $\mathbb{E}[Y|X = x_j]$ non è altro che calcolare una normalissima media di Y, ma utilizzando i "nuovi pesi" forniti dalla probabilità $\mathbb{Q}$ invece dei pesi originali dettati da $\mathbb{P}$.

La condizione di integrabilità
La definizione si conclude con una postilla fondamentale: il calcolo è valido *a patto che* $\mathbb{E}_{\mathbb{Q}}[|Y|] < \infty$. Questa condizione tecnica ci assicura che il valore atteso esista finito. Non basta che Y sia integrabile nell'universo originale $\mathbb{P}$; affinché la media condizionata abbia senso matematico, la variabile Y (in valore assoluto) deve non divergere all'infinito quando la si valuta sotto la nuova "lente" della probabilità $\mathbb{Q}$.

Anche Y è discreta

Se anche Y è discreta e assume una quantità numerabile di valori $\{y_1, ..., y_n, ...\}$, allora:

$$\mathbb{E}[Y|X = x_j] = \sum_{k=1}^{\infty} y_k \mathbb{P}(Y = y_k|X = x_j)$$

Questa espressione è l'esatto analogo della formula classica per il valore atteso $\mathbb{E}[Y] = \sum y_k \mathbb{P}(Y = y_k)$, ma con i "pesi" aggiornati. Invece di moltiplicare ogni possibile valore y_k per la sua probabilità marginale (a priori), lo moltiplichiamo per la sua **probabilità condizionata** (a posteriori), sapendo con certezza che l'evento $X = x_j$ si è verificato.

Il legame con la misura $\mathbb{Q}$
Riprendendo il concetto del "cambio di universo" visto in precedenza, le probabilità condizionate $\mathbb{P}(Y = y_k \mid X = x_j)$ non sono altro che i pesi della nuova misura $\mathbb{Q}(Y = y_k)$. Stiamo quindi eseguendo una normale media pesata dei valori di Y, ma utilizzando come pesi la nuova distribuzione di probabilità $\mathbb{Q}$ dettata dall'informazione su X.

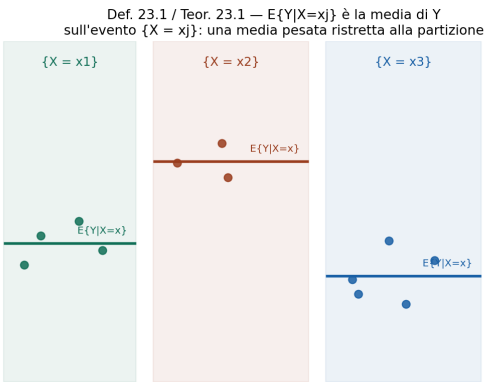


Figure 10: L'attesa condizionata $E\{Y \mid X = x_j\}$ è semplicemente la media di Y calcolata restringendosi all'evento $\{X = x_j\}$: ogni partizione ha la propria media locale.

3.2 Valore atteso condizionato di Y data X discreta

Sia X una variabile aleatoria a valori in un insieme numerabile $\{x_1, x_2, \dots\}$ e sia Y una variabile aleatoria a valori in $\mathbb{R}$ (con $\mathbb{E}[|Y|] < \infty$).

Il **valore atteso condizionato di Y data** X, indicato con $\mathbb{E}[Y|X]$, è definito come:

$$\mathbb{E}[Y|X] = f(X)$$

dove $f(x)$ è la funzione reale definita da:

$$f(x_j) = \mathbb{E}[Y|X = x_j] \quad \text{per ogni } x_j \text{ tale che } \mathbb{P}(X = x_j) > 0$$

Il salto concettuale: Numero vs Variabile Aleatoria
È cruciale notare la differenza rispetto alla sezione precedente:

- Condizionare a un evento specifico, come $\{X = x_j\}$, produce un **numero fisso** (la stima di Y sapendo esattamente cosa è successo).
- Condizionare rispetto all'intera variabile aleatoria X produce una **nuova variabile aleatoria**.

Perché è una variabile aleatoria?
L'espressione $\mathbb{E}[Y|X]$ descrive il modo in cui aggiorneremo la nostra stima di Y *prima* che l'esperimento venga eseguito. Poiché il risultato dipende dal valore (ancora ignoto e governato dal caso) che assumerà X, la quantità $f(X)$ è anch'essa governata dal caso. Nello specifico, $\mathbb{E}[Y|X]$ è una variabile aleatoria discreta che:

$$\text{assume il valore } \mathbb{E}[Y|X = x_j] \quad \text{con probabilità } \mathbb{P}(X = x_j)$$

Esempio

Sia X una variabile aleatoria con distribuzione di Poisson di parametro λ. Supponiamo che, dato l'evento $\{X = n\}$, eseguiamo n prove indipendenti, ciascuna con probabilità di successo p. Sia S il numero totale di successi ottenuti. Vogliamo calcolare $\mathbb{E}[S|X]$ e $\mathbb{E}[X|S]$.

1. Calcolo di $\mathbb{E}[S|X]$ (Il caso semplice)
Iniziamo fissando il valore di X. Se sappiamo che $X = n$, la variabile S (numero di successi in n prove) segue per definizione una distribuzione Binomiale di parametri n e p. Sappiamo che il valore atteso di una Binomiale è il prodotto dei suoi parametri:

$$\mathbb{E}[S|X = n] = np$$

Per la regola vista in precedenza (il passaggio da numero a variabile aleatoria), sostituendo il valore fisso n con la variabile X, otteniamo immediatamente:

$$\mathbb{E}[S|X] = pX$$

2. Calcolo di $\mathbb{E}[X|S]$ (Il caso complesso)
Questo calcolo è più insidioso perché dobbiamo procedere "a ritroso". Per trovare $\mathbb{E}[X|S=k]$, dobbiamo prima determinare la distribuzione di probabilità condizionata $\mathbb{P}(X=n|S=k)$. Utilizziamo il Teorema di Bayes e la Legge delle Probabilità Totali:

$$\mathbb{P}(X=n|S=k) = \frac{\mathbb{P}(S=k|X=n)\mathbb{P}(X=n)}{\mathbb{P}(S=k)} = \frac{\mathbb{P}(S=k|X=n)\mathbb{P}(X=n)}{\sum_{m\geq k}\mathbb{P}(S=k|X=m)\mathbb{P}(X=m)}$$

Nota sui limiti della sommatoria: La somma parte da $m=k$ perché è impossibile ottenere k successi se il numero totale di tentativi m è minore di k.

Sostituiamo le distribuzioni note (Binomiale per $S|X$ e Poisson per X):

$$\text{Numeratore} = \binom{n}{k}p^k(1-p)^{n-k}\frac{\lambda^n}{n!}e^{-\lambda}$$

Esplicitando il coefficiente binomiale $\binom{n}{k} = \frac{n!}{k!(n-k)!}$, il termine $n!$ si semplifica:

$$\text{Numeratore} = \frac{p^k(1-p)^{n-k}\lambda^n}{k!(n-k)!}e^{-\lambda}$$

Ora calcoliamo il **Denominatore** (che richiede un trucco algebrico). Riscriviamo la serie raggruppando i termini e portando fuori dalla sommatoria ciò che non dipende da m:

$$\text{Denominatore} = \sum_{m\geq k}\frac{p^k(1-p)^{m-k}\lambda^m}{k!(m-k)!}e^{-\lambda} = \frac{(\lambda p)^k e^{-\lambda}}{k!}\sum_{m\geq k}\frac{(\lambda(1-p))^{m-k}}{(m-k)!}$$

Facciamo un cambio di variabile: poniamo $j=m-k$. Quando m va da k a ∞, j va da 0 a ∞:

$$\sum_{j=0}^{\infty}\frac{(\lambda(1-p))^j}{j!}$$

Questa è esattamente l'espansione in serie di Taylor della funzione esponenziale $e^x = \sum\frac{x^j}{j!}$, con $x=\lambda(1-p)$. Quindi la somma vale $e^{\lambda(1-p)}$. Il denominatore si riduce a:

$$\text{Denominatore} = \frac{(\lambda p)^k e^{-\lambda}}{k!}e^{\lambda(1-p)} = \frac{(\lambda p)^k e^{-\lambda p}}{k!}$$

(Nota a margine: abbiamo appena dimostrato che la distribuzione marginale di S è una Poisson di parametro λp!)

Ora possiamo finalmente scrivere la probabilità condizionata dividendo Numeratore per Denominatore. Gran parte dei termini si semplificano:

$$\mathbb{P}(X=n|S=k) = \frac{\frac{p^k(1-p)^{n-k}\lambda^n}{k!(n-k)!}e^{-\lambda}}{\frac{(\lambda p)^k e^{-\lambda p}}{k!}} = \frac{(\lambda(1-p))^{n-k}}{(n-k)!}e^{-\lambda(1-p)}$$

Questa formula ci dice una cosa bellissima: dato $S=k$, la differenza $(X-k)$ segue una distribuzione di Poisson di parametro $\lambda(1-p)$.

Possiamo ora calcolare il valore atteso calcolando la serie:

$$\mathbb{E}[X|S=k] = \sum_{n\geq k} n\cdot\mathbb{P}(X=n|S=k) = \sum_{n\geq k} n\frac{(\lambda(1-p))^{n-k}}{(n-k)!}e^{-\lambda(1-p)}$$

Usando lo stesso cambio di variabile $j=n-k$ (quindi $n=j+k$):

$$\mathbb{E}[X|S=k] = \sum_{j=0}^{\infty}(j+k)\frac{(\lambda(1-p))^j}{j!}e^{-\lambda(1-p)}$$

Questa somma si spezza nel valore atteso di una Poisson di parametro $\lambda(1-p)$, che vale esattamente $\lambda(1-p)$, più la costante k.

$$\mathbb{E}[X|S=k] = \lambda(1-p) + k$$

Sostituendo il valore fisso k con la variabile aleatoria S, otteniamo il risultato finale:

$$\mathbb{E}[X|S] = S + \lambda(1-p)$$

3. Verifica tramite la Legge delle Aspettative Iterate
Come verifica finale, calcoliamo $\mathbb{E}[S]$ usando la proprietà della torre (o aspettativa iterata): $\mathbb{E}[S] = \mathbb{E}[\mathbb{E}[S|X]]$. Sostituendo il risultato trovato al punto 1:

$$\mathbb{E}[S] = \mathbb{E}[pX] = p\mathbb{E}[X]$$

Poiché X è una Poisson di parametro λ, il suo valore atteso è λ. Dunque:

$$\mathbb{E}[S] = p\lambda$$

Il che è coerente col fatto che S sia distribuita come una Poisson di parametro λp.

Cosa succede se X è una VA continua?

3.2.1 σ-algebra generata da una variabile aleatoria

Sia $X : (\Omega, \mathcal{A}) \to (\mathbb{R}^n, \mathcal{B}^n)$ una funzione misurabile. La σ-algebra generata da X, indicata con $\sigma(X)$, è definita come la controimmagine della σ-algebra boreliana $\mathcal{B}^n$ tramite la funzione X:

$$\sigma(X) = X^{-1}(\mathcal{B}^n)$$

Ovvero, esplicitando la definizione come avevamo già visto:

$$\sigma(X) = \{A \subseteq \Omega \mid A = X^{-1}(B) \quad \text{per qualche } B \in \mathcal{B}^n\}$$

Nella teoria moderna della probabilità, la σ-algebra $\sigma(X)$ è la traduzione matematica rigorosa del concetto di **informazione portata da** X. Cosa c'è dentro l'insieme $\sigma(X)$? Ci sono tutti e soli quegli eventi A (sottoinsiemi di Ω) per i quali possiamo stabilire con assoluta certezza se si sono verificati o meno, basandoci *unicamente* sull'osservazione del valore assunto da X.

È per questo motivo che nel Lemma di Doob-Dynkin diciamo che se Y è $\sigma(X)$-misurabile, allora Y dipende totalmente da X: significa che l'informazione portata da X è sufficiente a determinare tutto ciò che fa Y.

Lemma di Doob-Dynkin (o Teorema di Fattorizzazione)

Sia X una variabile aleatoria a valori in $\mathbb{R}^n$ e sia Y una variabile aleatoria a valori in $\mathbb{R}$. Y è $\sigma(X)$-misurabile se e solo se esiste una funzione Borel-misurabile $f : \mathbb{R}^n \to \mathbb{R}$ tale che:

$$Y = f(X)$$

Per comprendere questo lemma, bisogna pensare alla σ-algebra $\sigma(X)$ come all'**informazione portata da** X.

- Dire che "Y è $\sigma(X)$-misurabile" significa che se noi conosciamo il risultato dell'esperimento per X, allora conosciamo automaticamente e senza alcuna incertezza anche il risultato di Y.
- Il lemma ci dice che questa dipendenza totale a livello di informazione si traduce sempre in una **dipendenza funzionale deterministica**: se Y non aggiunge "nuova casualità" rispetto a X, allora Y deve per forza essere una funzione matematica esatta di X.

Il legame con il Valore Atteso Condizionato

Questo lemma è il pilastro teorico su cui si poggia la definizione moderna di valore atteso condizionato. Per definizione (che si basa sul Teorema di Radon-Nikodym o sul Teorema della Proiezione), sappiamo che la variabile aleatoria $Z = \mathbb{E}[Y|X]$ deve essere $\sigma(X)$-misurabile. Applicando il Lemma di Doob-Dynkin a Z, otteniamo la garanzia matematica che deve esistere una funzione f tale per cui:

$$\mathbb{E}[Y|X] = f(X)$$

Ecco spiegato rigorosamente perché il valore atteso condizionato rispetto a una variabile aleatoria è sempre una funzione di quella variabile!

3.3 Valore atteso condizionato di Y data X (Caso L^2 e Generale)

Sia $Y \in L^2(\Omega, \mathcal{A}, \mathbb{P})$ (ovvero lo spazio di tutte le variabili aleatorie con varianza finita nell'intero universo Ω). Allora il valore atteso condizionato di Y data X è definito come l'unico elemento $\hat{Y} \in L^2(\Omega, \sigma(X), \mathbb{P})$ tale che:

$$\mathbb{E}[\hat{Y}Z] = \mathbb{E}[YZ] \quad \forall Z \in L^2(\Omega, \sigma(X), \mathbb{P})$$

Scriviamo $\mathbb{E}[Y|X]$ per indicare esplicitamente $\hat{Y}$.

Il legame con l'Ortogonalità dell'errore (Teorema della Proiezione)

Questa definizione algebrica, apparentemente astratta, è l'esatta traduzione probabilistica del *Teorema della Proiezione* negli spazi di Hilbert. Sappiamo che lo spazio vettoriale limitato dall'informazione di X, ovvero $L^2(\Omega, \sigma(X), \mathbb{P})$, è un sottospazio chiuso di $L^2(\Omega, \mathcal{A}, \mathbb{P})$.

Il valore atteso condizionato $\hat{Y}$ è semplicemente la **proiezione ortogonale** di Y su questo sottospazio. Per le proprietà dell'operatore di proiezione, il termine residuo (o errore di stima) definito come $(Y - \hat{Y})$ deve essere ortogonale a tutto il sottospazio. Nello spazio L^2, il prodotto scalare è definito come $\langle U, V \rangle = \mathbb{E}[UV]$. Di conseguenza, imporre l'ortogonalità dell'errore significa richiedere che, per ogni Z nel sottospazio:

$$\langle Y - \hat{Y}, Z \rangle = 0 \implies \mathbb{E}[(Y - \hat{Y})Z] = 0$$

- Y è la variabile che vogliamo prevedere
- $\hat{Y} = \mathbb{E}[Y|X]$ è la nostra migliore stima basata solo sull'informazione di X ($\sigma(X)$)
- $Y - \hat{Y}$ è il residuo, o errore
- Z è un qualsiasi modo di sfruttare l'informazione X (una qualsiasi funzione Borel-misurabile $g(X)$).

Sfruttando la linearità del valore atteso, otteniamo:

$$\mathbb{E}[YZ] - \mathbb{E}[\hat{Y}Z] = 0 \implies \mathbb{E}[YZ] = \mathbb{E}[\hat{Y}Z]$$

Ecco da dove deriva la definizione principale! Questa proprietà ci garantisce non solo che $\mathbb{E}[Y|X]$ esiste, ma anche che è unico, proprio perché è la migliore approssimazione possibile di Y date le informazioni fornite da X.

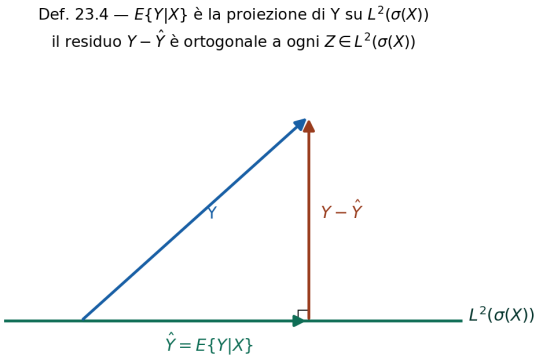


Figure 11: $\hat{Y} = E\{Y \mid X\}$ è la proiezione ortogonale di Y sul sottospazio chiuso $L^2(\sigma(X))$; il residuo $Y - \hat{Y}$ è ortogonale a ogni $Z \in L^2(\sigma(X))$.

Applicazione del Lemma di Doob-Dynkin
Poiché, per definizione, la variabile $\mathbb{E}[Y|X]$ appartiene allo spazio limitato da $\sigma(X)$, essa è $\sigma(X)$-misurabile. Per il Lemma di Doob-Dynkin, deve esistere una funzione Borel-misurabile f tale per cui:

$$\mathbb{E}[Y|X] = f(X)$$

Allo stesso modo, il generico "vettore di test" Z può essere scritto come $g(X)$. Pertanto, la definizione $\mathbb{E}[\hat{Y}Z] = \mathbb{E}[YZ]$ assume la sua forma operativa più utile negli esercizi:

$$\mathbb{E}[f(X)g(X)] = \mathbb{E}[Yg(X)]$$

per ogni funzione g Borel-misurabile tale che $g(X) \in L^2$.

Generalizzazione a una σ-algebra generica
Questo potente impianto geometrico non vale solo per il condizionamento rispetto a una variabile aleatoria X, ma può essere esteso. Se sostituiamo $\sigma(X)$ con una qualsiasi σ-algebra $\mathcal{G} \subset \mathcal{A}$ (che rappresenta un set generico di informazioni), lo spazio $L^2(\Omega, \mathcal{G}, \mathbb{P})$ rimane un sottospazio chiuso di Hilbert. Possiamo quindi definire in modo del tutto analogo la proiezione ortogonale $\mathbb{E}[Y|\mathcal{G}]$, che rappresenta il valore atteso condizionato di Y dato il bagaglio informativo $\mathcal{G}$.

Ma cosa rappresenta esattamente la variabile Z?

Nella definizione $\mathbb{E}[\hat{Y}Z] = \mathbb{E}[YZ]$, la variabile aleatoria Z funge da **"vettore di test"**. Possiamo comprenderne il significato da due prospettive complementari:

1. La prospettiva Geometrica (Spazi di Hilbert)

Nel Teorema della Proiezione, abbiamo detto che l'errore di approssimazione $(Y - \hat{Y})$ deve essere ortogonale a *tutti* gli elementi del sottospazio su cui stiamo proiettando. Nello spazio L^2, il nostro "piano" (il sottospazio) è $L^2(\Omega, \sigma(X), \mathbb{P})$. La variabile Z rappresenta semplicemente un **generico vettore di questo piano**. Imporre $\mathbb{E}[(Y - \hat{Y})Z] = 0$ per *ogni* Z significa assicurarsi che l'errore sia a 90° rispetto a qualsiasi direzione possibile all'interno del sottospazio delle informazioni di X.

2. La prospettiva Probabilistica e dell'Informazione

Poiché Z vive nel sottospazio limitato da $\sigma(X)$, il Lemma di Doob-Dynkin ci assicura che Z non è altro che **una qualsiasi funzione di** X (cioè $Z = g(X)$). In questo senso, Z rappresenta un qualsiasi modo in cui potremmo rielaborare l'informazione X che già possediamo (ad esempio: X^2, e^X, $\sin(X)$, ecc.).

Dire che $\mathbb{E}[(Y - \hat{Y})g(X)] = 0$ per ogni funzione g significa che l'errore di stima $(Y - \hat{Y})$ è **completamente scorrelato** da qualsiasi possibile rielaborazione della nostra informazione di partenza. Se ci fosse anche solo una funzione $g(X)$ per cui questo prodotto non è zero, significherebbe che l'errore contiene ancora delle tracce di X: vorrebbe dire che la nostra stima $\hat{Y}$ non ha "spremuto" e utilizzato tutta l'informazione che X aveva da offrirci!

3.4 Valore atteso condizionato rispetto a una sub-σ-algebra

Sia $Y \in L^2(\Omega, \mathcal{A}, \mathbb{P})$ e sia $\mathcal{G}$ una sub-σ-algebra di $\mathcal{A}$ (ovvero $\mathcal{G} \subset \mathcal{A}$). Allora il valore atteso condizionato di Y data $\mathcal{G}$ è l'unico elemento $\mathbb{E}[Y|\mathcal{G}]$ che appartiene allo spazio $L^2(\Omega, \mathcal{G}, \mathbb{P})$ tale che:

$$\mathbb{E}[YZ] = \mathbb{E}[\mathbb{E}[Y|\mathcal{G}]Z] \quad \forall Z \in L^2(\Omega, \mathcal{G}, \mathbb{P})$$

Cosa cambia rispetto a prima?

Dal punto di vista matematico, non cambia assolutamente nulla: stiamo ancora proiettando ortogonalmente. La differenza è puramente concettuale. Invece di limitare la nostra informazione a una singola variabile aleatoria X (usando $\sigma(X)$), stiamo generalizzando a una *qualunque* libreria di informazioni rappresentata dalla σ-algebra $\mathcal{G}$. Questa $\mathcal{G}$ potrebbe essere generata da un intero vettore di variabili aleatorie $(X_1, X_2, \ldots, X_n)$, oppure dall'intera storia passata di un processo stocastico (come avviene nelle *martingale*).

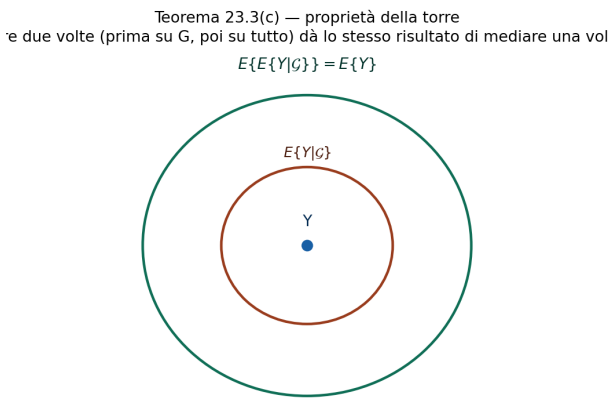


Figure 12: La proprietà della torre: $E\{E\{Y \mid \mathcal{G}\}\} = E\{Y\}$. Mediare due volte, prima su $\mathcal{G}$ e poi su tutto Ω, dà lo stesso risultato di mediare una sola volta.

Proprietà del Valore Atteso Condizionato

Sia $Y \in L^2(\Omega, \mathcal{A}, \mathbb{P})$ e sia $\mathcal{G}$ una sub-σ-algebra di $\mathcal{A}$. Valgono le seguenti proprietà:

- **Positività (o Monotonia)**:
  Se $Y \geq 0$, allora $\mathbb{E}[Y|\mathcal{G}] \geq 0$.
  (Di conseguenza, se $Y_1 \geq Y_2$, allora $\mathbb{E}[Y_1|\mathcal{G}] \geq \mathbb{E}[Y_2|\mathcal{G}]$).
- **Fattorizzazione di Doob-Dynkin**:
  Se $\mathcal{G} = \sigma(X)$ per qualche variabile aleatoria X, allora esiste una funzione Borel-misurabile f tale che:
  $$\mathbb{E}[Y|\sigma(X)] = f(X)$$
- **Proprietà della Torre (Aspettative Iterate)**:
  Prendendo il valore atteso (non condizionato) del valore atteso condizionato, si recupera il valore atteso originale:
  $$\mathbb{E}[\mathbb{E}[Y|\mathcal{G}]] = \mathbb{E}[Y]$$
  Nota più generale: Se abbiamo due σ-algebre annidate $\mathcal{H} \subset \mathcal{G}$, l'informazione minore "vince" sempre: $\mathbb{E}[\mathbb{E}[Y|\mathcal{G}]|\mathcal{H}] = \mathbb{E}[Y|\mathcal{H}]$.
- **Linearità**:
  Siano Y_1, Y_2 due variabili aleatorie e $\alpha, \beta \in \mathbb{R}$ due costanti scalari:
  $$\mathbb{E}[\alpha Y_1 + \beta Y_2|\mathcal{G}] = \alpha\mathbb{E}[Y_1|\mathcal{G}] + \beta\mathbb{E}[Y_2|\mathcal{G}]$$
- **Portar fuori ciò che è noto (Pulling out known factors)**:
  Se una variabile aleatoria Z è già $\mathcal{G}$-misurabile (ovvero il suo valore è perfettamente noto data l'informazione $\mathcal{G}$), essa si comporta come una costante rispetto al valore atteso condizionato e può "uscire" dall'operatore:
  $$\mathbb{E}[ZY|\mathcal{G}] = Z \cdot \mathbb{E}[Y|\mathcal{G}]$$

3.5 Il passaggio da L^2 a L^1

Fino ad ora siamo rimasti nel rassicurante spazio di Hilbert L^2. Qui tutto funzionava perfettamente poiché L^2 è dotato di un prodotto scalare, definito come $\langle X, Y \rangle = \mathbb{E}[XY]$. Tuttavia, appartengono ad L^2 solo le variabili aleatorie con momento secondo finito, ovvero $\mathbb{E}[|X|^2] < \infty$.

Le variabili aleatorie con varianza infinita, ma media finita ($\mathbb{E}[|X|] < \infty$), appartengono invece allo spazio L^1, che è uno **Spazio di Banach**.
Se proviamo ad usare la proiezione ortogonale sulle variabili in L^1, la matematica va in tilt: il Teorema di Pitagora perde di significato se l'ipotenusa è infinita.

Lo spazio di Banach è completo e normato, ma è sprovvisto di prodotto scalare e, di conseguenza, del

concetto stesso di "ortogonalità". Per definire e dimostrare che il **valore atteso condizionato** continua a esistere ed è unico anche in L^1, dovremo abbandonare le proiezioni geometriche e affidarci interamente alla teoria della misura: questo ci porterà al fondamentale **Teorema di Radon-Nikodym**.

Misurabilità e identità: quando $\mathbb{E}[Y|\mathcal{G}]$

Sia Y una variabile aleatoria (positiva o integrabile) definita sullo spazio $(\Omega, \mathcal{A}, \mathbb{P})$ e sia $\mathcal{G} \subset \mathcal{A}$ una sub-σ-algebra. Allora si ha che:

$$\mathbb{E}[Y|\mathcal{G}] = Y \quad \text{se e solo se} \quad Y \text{ è } \mathcal{G}\text{-misurabile.}$$

Significato Intuitivo (L'Informazione Totale)
Se Y è $\mathcal{G}$-misurabile, significa che l'informazione contenuta in $\mathcal{G}$ è *già sufficiente* per conoscere il valore esatto di Y. Non c'è più nulla da stimare: se l'esito è già noto date le informazioni a disposizione, la nostra "migliore previsione" diventa una certezza matematica e coincide con la variabile stessa.
Significato Geometrico (L'ombra sul pavimento)
Riprendendo il Teorema della Proiezione (valido nello spazio L^2), possiamo immaginare la σ-algebra $\mathcal{G}$ come il nostro "pavimento", ovvero il sottospazio lineare di tutte le variabili aleatorie che possiamo costruire con le informazioni a nostra disposizione.
Sappiamo che $\mathbb{E}[Y|\mathcal{G}]$ rappresenta la proiezione ortogonale, ovvero l'*ombra* del vettore Y gettata su quel pavimento. Se Y è $\mathcal{G}$-misurabile, geometricamente significa che il vettore Y si trova *già interamente adagiato sul pavimento*. Di conseguenza, la sua proiezione non lo sposta di un millimetro: l'ombra e il vettore coincidono perfettamente.

Indipendenza

Sia $Y \in L^1(\Omega, \mathcal{A}, \mathbb{P})$ e supponiamo che X e Y siano indipendenti. Allora:

$$\mathbb{E}[Y|X] = \mathbb{E}[Y]$$

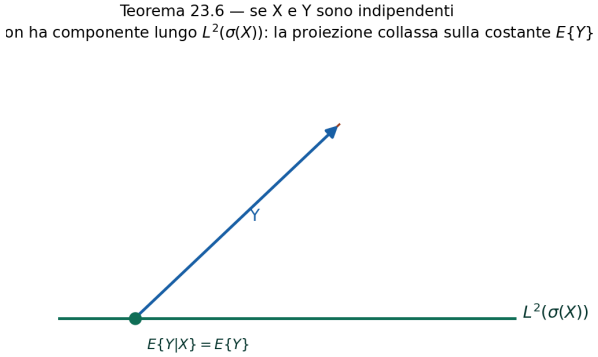


Figure 13: Se X e Y sono indipendenti, Y non ha componente lungo $L^2(\sigma(X))$: la proiezione collassa sulla costante, e $E\{Y \mid X\} = E\{Y\}$.

3.6 Disuaguaglianze Fondamentali

3.6.1 Disuguaglianza di Jensen (Versione Condizionata)

Sia $\phi : \mathbb{R} \to \mathbb{R}$ una funzione convessa, e siano X e $\phi(X)$ variabili aleatorie integrabili. Per ogni sub-σ-algebra $\mathcal{G}$, vale la disuguaglianza:

$$\phi\left(\mathbb{E}[X|\mathcal{G}]\right) \leq \mathbb{E}[\phi(X)|\mathcal{G}]$$

Significato Intuitivo
In parole povere questa disuguaglianza afferma che: *"La funzione della media è sempre minore o uguale alla media della funzione".*

Conseguenza fondamentale: La Varianza Condizionata
Notiamo che la funzione $\phi(x) = x^2$ è convessa. Applicando la disuguaglianza di Jensen otteniamo:

$$(\mathbb{E}[X|\mathcal{G}])^2 \leq \mathbb{E}[X^2|\mathcal{G}]$$

Questa disuguaglianza ha un'implicazione importantissima. Se riordiniamo i termini portandoli tutti a destra, otteniamo:

$$\mathbb{E}[X^2|\mathcal{G}] - (\mathbb{E}[X|\mathcal{G}])^2 \geq 0$$

La quantità a sinistra è l'esatta definizione della **varianza condizionata** $\mathrm{Var}(X|\mathcal{G})$. Dunque, la disuguaglianza di Jensen ci garantisce matematicamente che, proprio come la varianza classica, anche la varianza condizionata non può mai assumere valori negativi.

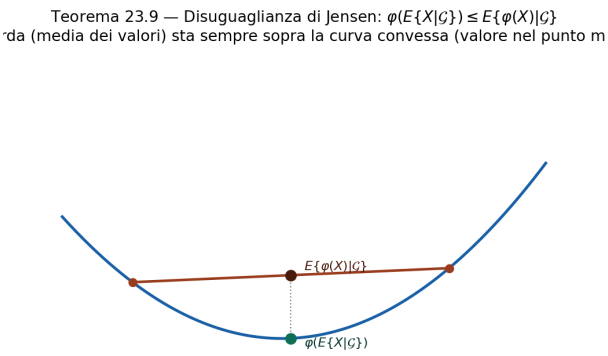


Figure 14: Disuguaglianza di Jensen: $\varphi(E\{X \mid \mathcal{G}\}) \leq E\{\varphi(X) \mid \mathcal{G}\}$. Per una funzione convessa, la corda (media dei valori) sta sempre sopra la curva (valore nel punto medio).

3.6.2 Disuguaglianza di Hölder

Siano X e Y due variabili aleatorie tali che $\mathbb{E}[|X|^p] < \infty$ e $\mathbb{E}[|Y|^q] < \infty$, dove p e q (con $p, q > 1$) sono **esponenti coniugati**, ovvero soddisfano la relazione:

$$\frac{1}{p} + \frac{1}{q} = 1$$

Allora vale la seguente catena di disuguaglianze:

$$|\mathbb{E}[XY]| \leq \mathbb{E}[|XY|] \leq (\mathbb{E}[|X|^p])^{1/p} (\mathbb{E}[|Y|^q])^{1/q}$$

Di conseguenza, se $X \in L^p$ e $Y \in L^q$, allora il loro prodotto appartiene allo spazio L^1, ovvero $XY \in L^1$ (il prodotto è integrabile e ammette valore atteso finito).

Il significato pratico
La disuguaglianza di Hölder serve a stabilire un **limite superiore** rigoroso a quanto può essere grande il valore atteso del prodotto di due variabili aleatorie. Questa proprietà è uno strumento di controllo

fondamentale: ci garantisce che quantità che dipendono dal prodotto di due variabili (come la covarianza o la correlazione) non "esplodano" all'infinito, a patto di poter controllare i momenti p-esimo e q-esimo delle singole variabili isolate.

Osservazione: Il legame con Cauchy-Schwarz e L^2
Nel capitolo precedente abbiamo visto che, nello spazio di Hilbert L^2, la finitezza e la validità dell'inner product (il prodotto scalare) sono garantite dalla disuguaglianza di Cauchy-Schwarz:

$$|\mathbb{E}[XY]| \leq (\mathbb{E}[X^2])^{1/2}(\mathbb{E}[Y^2])^{1/2}$$

Possiamo ora notare che la disuguaglianza di Hölder non è altro che la sua naturale generalizzazione a spazi normati diversi. Se infatti poniamo $p = 2$ e $q = 2$ (che soddisfano banalmente la condizione degli esponenti coniugati poiché $1/2 + 1/2 = 1$), la disuguaglianza di Hölder collassa esattamente nella Cauchy-Schwarz.

3.6.3 Disuguaglianza di Minkowski

Siano X e Y due variabili aleatorie e $1 \leq p < \infty$, con $\mathbb{E}[|X|^p] < \infty$ e $\mathbb{E}[|Y|^p] < \infty$ (ovvero $X, Y \in L^p$). Allora vale la seguente disuguaglianza:

$$(\mathbb{E}[|X + Y|^p])^{1/p} \leq (\mathbb{E}[|X|^p])^{1/p} + (\mathbb{E}[|Y|^p])^{1/p}$$

Significato geometrico: la Disuguaglianza Triangolare in L^p
La disuguaglianza di Minkowski è fondamentale perché ci permette di definire rigorosamente una **norma** sullo spazio L^p. Se definiamo la "lunghezza" di una variabile aleatoria X come la sua norma p-esima, indicata con $\|X\|_p = (\mathbb{E}[|X|^p])^{1/p}$, l'equazione precedente si può riscrivere in modo molto più familiare:

$$\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$$

Proprio come avevamo visto che la disuguaglianza di Hölder è la generalizzazione della Cauchy-Schwarz, questa notazione rende evidente che **la disuguaglianza di Minkowski è la generalizzazione della disuguaglianza triangolare**. Essa ci garantisce, anche in spazi a infinite dimensioni, un fatto geometrico intuitivo: la distanza del cammino diretto (la somma $X + Y$) è sempre minore o uguale alla somma dei due cammini separati.

3.7 La norma in L^p e la geometria degli spazi

Per poter definire rigorosamente la "lunghezza" di un oggetto matematico (ovvero una **norma** $\|\cdot\|$), la funzione scelta deve rispettare tre assiomi fondamentali:

- **Omogeneità assoluta:** Deve scalare proporzionalmente. Se moltiplico una variabile per una costante c, la sua "lunghezza" viene moltiplicata per il valore assoluto della costante ($\|cX\| = |c|\|X\|$).
- **Disuguaglianza triangolare:** Il cammino diretto è sempre più breve della somma di due cammini separati ($\|X + Y\| \leq \|X\| + \|Y\|$).
- **Definitezza (o Separazione):** La norma è 0 se e solo se l'oggetto è il vettore nullo ($\|X\| = 0 \iff X = 0$).

Per una variabile aleatoria $X \in L^p$, definiamo la norma p-esima come:

$$\|X\|_p = (\mathbb{E}[|X|^p])^{1/p} = \left(\int_\Omega |X(\omega)|^p d\mathbb{P}(\omega)\right)^{1/p}$$

Dalla Minkowski agli Spazi di Banach
Il fatto che questa formula sia davvero una norma dipende interamente dalla **disuguaglianza di Minkowski**, che dimostra il rispetto della disuguaglianza triangolare. Questo risultato ci garantisce che L^p è a tutti gli effetti uno spazio lineare normato.

Di fatto, è persino uno spazio normato *completo* (ovvero uno **Spazio di Banach**). Tuttavia, per $p \neq 2$ non è uno Spazio di Hilbert, poiché la sua norma non deriva da alcun prodotto scalare sottostante (viene a mancare l'identità del parallelogramma).

Nota tecnica (Il concetto di "Quasi Certamente"):
In probabilità, la condizione di definitezza ($\|X\|_p = 0 \iff X = 0$) è soddisfatta in senso debole, ovvero $X = 0$ *quasi certamente* (con probabilità 1). Per questo motivo, per far funzionare la geometria, lo spazio L^p non è formato da singole funzioni, ma da "classi di equivalenza": due variabili aleatorie che differiscono solo su un evento di probabilità nulla vengono considerate esattamente come lo stesso vettore matematico.

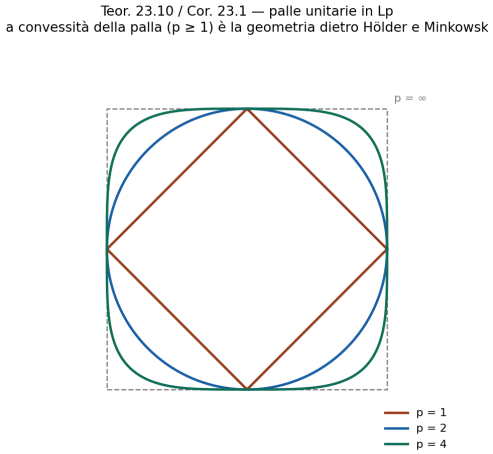


Figure 15: Le palle unitarie di L^p per $p = 1, 2, 4, \infty$: la loro convessità per $p \geq 1$ è la geometria che sottende le disuguaglianze di Hölder e di Minkowski.

3.8 MCT, Lemma di Fatou e DCT condizionati

Quando è lecito scambiare limite e integrale? Poiché il valore atteso condizionato non è altro che un integrale di Lebesgue (valutato rispetto a una nuova misura di probabilità dettata dalle informazioni), i tre teoremi fondamentali dell'integrazione continuano a valere anche sotto condizionamento.

Nota bene: Poiché $\mathbb{E}[\cdot|\mathcal{G}]$ produce una nuova variabile aleatoria, tutte le uguaglianze e le disuguaglianze che seguono sono da intendersi **Quasi Certamente** (A.S. - Almost Surely), ovvero sono vere con probabilità 1.

Sia $\{Y_n\}_{n\geq 1}$ una successione di variabili aleatorie su $(\Omega, \mathcal{A}, \mathbb{P})$ e sia $\mathcal{G}$ una sub-σ-algebra di $\mathcal{A}$. Valgono i seguenti risultati:

- **Teorema della Convergenza Monotona (MCT)**:
  Se $Y_n \geq 0$ e la successione cresce verso Y quasi certamente ($Y_n \uparrow Y$ a.s.), allora il limite passa dentro l'aspettativa:
  $$\lim_{n\to\infty} \mathbb{E}[Y_n|\mathcal{G}] = \mathbb{E}[Y|\mathcal{G}] \quad \text{a.s.}$$

- **Lemma di Fatou**:
  Se $Y_n \geq 0$, allora l'aspettativa del limite inferiore è sempre dominata dal limite inferiore delle aspettative:
  $$\mathbb{E}\left[\liminf_{n\to\infty} Y_n \middle| \mathcal{G}\right] \leq \liminf_{n\to\infty} \mathbb{E}[Y_n|\mathcal{G}] \quad \text{a.s.}$$

- **Teorema della Convergenza Dominata (DCT)**:
  Se $\lim_{n\to\infty} Y_n = Y$ quasi certamente e la successione è "dominata" da una variabile integrabile, ovvero esiste $Z \in L^1(\Omega, \mathcal{A}, \mathbb{P})$ tale che $|Y_n| \leq Z$ per ogni n, allora:
  $$\lim_{n\to\infty} \mathbb{E}[Y_n|\mathcal{G}] = \mathbb{E}[Y|\mathcal{G}] \quad \text{a.s.}$$